Streszczenie

Termografia może uzupełniać ocenę zmian skórnych na zdjęciach o informację o rozkładzie temperatury skóry, ale wspólna analiza obu obrazów wymaga ich rejestracji. Zdjęcie z telefonu i obraz termowizyjny pochodzą z niezależnych urządzeń, a znamię bez schłodzenia skóry nie jest widoczne na termogramie. Celem pracy było opracowanie, implementacja oraz ocena systemu, który rejestruje zdjęcie RGB i obraz termowizyjny zmiany skórnej, przenosi obszar zainteresowania między modalnościami, wyznacza jego parametry ilościowe i weryfikuje zgodność obszaru za pomocą modeli segmentacji dedykowanych każdej modalności. Zaprojektowano znacznik referencyjny w kształcie litery Π, widoczny w obu modalnościach, i metodę rejestracji maksymalizującą kryterium ECC na maskach znacznika. Znamię na zdjęciu segmentuje model PanDerm z dekoderem UperNet douczony na zbiorze ISIC 2018, a znacznik na obrazie termowizyjnym – sieć U-Net uczona na danych własnych. System wyznacza wymiary znamienia w milimetrach, miary zgodności masek oraz współrzędne i surową intensywność pikseli obrazu termowizyjnego w obszarze znamienia, a wyniki zapisuje w raporcie i bazie danych SQLite. Weryfikację przeprowadzono na 94 parach obrazów 34 znamion. Mediana błędu rejestracji wyniosła 0,61 mm (w 85% par nie więcej niż 1 mm), wobec 3,36 mm dla rejestracji z użyciem informacji wzajemnej. Sieć U-Net uzyskała współczynnik Dice'a 0,969, a model PanDerm na zdjęciach z telefonu – 0,870. Zgodność masek znacznika między modalnościami, wyznaczana bez adnotacji (Dice 0,957), była silnie skorelowana z błędem rejestracji, co pozwala wskazywać pary wymagające sprawdzenia.

Słowa kluczowe: rejestracja obrazów wielomodalnych, termowizja, segmentacja obrazów medycznych, znamię barwnikowe, znacznik referencyjny, uczenie głębokie.
Dziedzina nauki i techniki, zgodnie z wymogami OECD: nauki inżynieryjne i techniczne, inżynieria medyczna.

Abstract

Thermal imaging can complement the assessment of skin lesions in photographs with information on skin temperature distribution, but a joint analysis of both images requires their registration. A smartphone photograph and a thermal image come from independent devices, and a nevus is not visible in a thermogram unless the skin is cooled. The aim of this thesis was to design, implement and evaluate a system that registers an RGB photograph and a thermal image of a skin lesion, transfers the region of interest between the modalities, computes its quantitative parameters, and verifies the agreement of the region using segmentation models dedicated to each modality. A Π-shaped fiducial marker visible in both modalities was designed, together with a registration method that maximizes the enhanced correlation coefficient (ECC) on marker masks. The nevus in the photograph is segmented by the PanDerm foundation model with an UperNet decoder fine-tuned on the ISIC 2018 dataset, and the marker in the thermal image by a U-Net trained on the author's data. The system measures the lesion in millimeters, computes mask agreement metrics, and exports the coordinates and raw intensity of every thermal image pixel within the lesion; the results are stored in a report and an SQLite database. The system was evaluated on 94 image pairs of 34 nevi. The median target registration error was 0.61 mm (at most 1 mm in 85% of pairs), compared with 3.36 mm for mutual information registration. The U-Net achieved a Dice coefficient of 0.969, and PanDerm achieved 0.870 on smartphone photographs. The agreement of marker masks between modalities, computed without annotations (Dice 0.957), was strongly correlated with the registration error, which allows pairs requiring inspection to be identified.

Keywords: multimodal image registration, thermal imaging, medical image segmentation, melanocytic nevus, fiducial marker, deep learning.
Field of science and technology in accordance with OECD requirements: engineering and technology, medical engineering.

Spis treści

Streszczenie **1**

Abstract **2**

Wykaz ważniejszych oznaczeń i skrótów **5**

1 Wstęp **8**
1.1 Motywacja 8
1.2 Cel i zakres pracy 9
1.3 Struktura pracy 10

2 Analiza stanu wiedzy **11**
2.1 Obrazowanie zmian skórnych 11
2.2 Rejestracja obrazów wielomodalnych 12
2.2.1 Modele transformacji i miary podobieństwa 12
2.2.2 Rejestracja obrazów widzialnych i termowizyjnych 13
2.2.3 Metody oparte na uczeniu głębokim 13
2.2.4 Fuzja i wizualizacja nałożenia 14
2.3 Segmentacja obrazów medycznych 14
2.3.1 Metody klasyczne 14
2.3.2 Sieć U-Net i architektury koder–dekoder 14
2.3.3 Modele bazowe w dermatologii i zbiory danych 15
2.3.4 Segmentacja obrazów termowizyjnych 16
2.4 Miary oceny rejestracji i segmentacji 16
2.5 Podsumowanie i luka badawcza 17

3 Analiza projektowa **19**
3.1 Założenia i ograniczenia 19
3.2 Wymagania funkcjonalne 20
3.3 Wymagania pozafunkcjonalne 20
3.4 Przypadki użycia 20
3.5 Architektura systemu 22

4 Projekt systemu **25**
4.1 Dobór technologii 25
4.2 Projekt znacznika referencyjnego 25
4.3 Projekt bazy danych 27
4.4 Diagram klas 29
4.5 Projekt interfejsu użytkownika 29

5 Implementacja **31**
5.1 Akwizycja i przygotowanie danych . . . 31
5.2 Moduł rejestracji . . . 32
5.2.1 Detekcja znacznika . . . 32
5.2.2 Dopasowanie wstępne i doprecyzowanie metodą ECC . . . 32
5.2.3 Wybór modelu przekształcenia . . . 32
5.3 Modele segmentacji . . . 33
5.3.1 Model M1 – znamię na zdjęciu . . . 34
5.3.2 Model M3 – znacznik na obrazie termowizyjnym . . . 35
5.4 Przeniesienie obszarów i skala metryczna . . . 35
5.5 Pomiary i miary zgodności . . . 36
5.6 Baza danych, raport i aplikacja . . . 36

6 Testy i wyniki **38**
6.1 Zbiór danych i protokół oceny . . . 38
6.2 Dokładność rejestracji . . . 38
6.3 Jakość segmentacji w obu modalnościach . . . 40
6.4 Zgodność obszaru zainteresowania między modalnościami . . . 41
6.5 Parametry znamion i piksele na obrazie termowizyjnym . . . 41
6.6 Testy funkcjonalne . . . 43
6.7 Dyskusja i ograniczenia . . . 43

7 Podsumowanie **45**
7.1 Realizacja celu pracy . . . 45
7.2 Wnioski . . . 45
7.3 Kierunki dalszych prac . . . 46

A Instrukcja użytkownika **49**
A.1 Uruchomienie . . . 49
A.2 Przygotowanie obrazów . . . 49
A.3 Analiza pary krok po kroku . . . 49
A.4 Wyniki . . . 50
A.5 Komunikaty i rozwiązywanie problemów . . . 50

B Dokumentacja techniczna **52**
B.1 Środowiska i instalacja . . . 52
B.2 Struktura kodu . . . 53
B.3 Formaty danych . . . 53
B.4 Baza danych . . . 54
B.5 Skrypty pomocnicze, uczenie i testy . . . 54
B.6 Rozszerzanie systemu . . . 54

Wykaz ważniejszych oznaczeń i skrótów

Oznaczenia

A, B	porównywane maski; w badaniu E2: A – maska przeniesiona ze zdjęcia, B – maska wyznaczona na obrazie termowizyjnym
$\|A\|$	pole maski A
d	średnica równoważna znamienia
e	średni błąd krawędzi masek znacznika
G_σ	filtr Gaussa o odchyleniu standardowym σ
H, H_T	homografia przekształcająca piksele obrazu na milimetry w płaszczyźnie znacznika; H_T – dla obrazu termowizyjnego
I	surowa wartość detektora (intensywność) piksela obrazu termowizyjnego
L, P	obwód i pole znamienia
M_R, M_T	maska znacznika na zdjęciu i na obrazie termowizyjnym
p_i^R, p_i^T	i-ty narożnik znacznika na zdjęciu i na obrazie termowizyjnym
P1–P8	narożniki znacznika Π
T	macierz rejestracji 3×3 (piksel zdjęcia $\rightarrow$ piksel obrazu termowizyjnego)
u	ułamek pola piksela pokryty przez znamię
W_0, W_A, W_H	przekształcenie: wstępne (podobieństwo), afiniczne, homografia
x, y	współrzędne piksela: kolumna i wiersz
η	współczynnik uczenia
ε	próg zbieżności metody ECC
λ	współczynnik regularyzacji wag (ang. *weight decay*)
Π	znacznik referencyjny w kształcie litery Π
ρ	współczynnik korelacji rang Spearmana
σ	odchylenie standardowe; parametr rozmycia filtrem Gaussa
j.s.	jednostki surowe detektora kamery termowizyjnej

Skróty

ASSD	średnia symetryczna odległość konturów (ang. *average symmetric surface distance*)
BCE	binarna entropia krzyżowa (ang. *binary cross-entropy*)
CSV	plik tekstowy z wartościami rozdzielonymi separatorem (ang. *comma-separated values*)
CUDA	platforma obliczeń równoległych na procesorach graficznych (ang. *Compute Unified Device Architecture*)
CVAT	program do adnotacji obrazów (ang. *Computer Vision Annotation Tool*)
DSC	współczynnik Dice'a (ang. *Dice similarity coefficient*)

E1, E2, E4	badania weryfikacyjne: E1 – dokładność rejestracji względem adnotacji, E2 – zgodność masek znacznika między modalnościami bez adnotacji, E4 – porównanie metod rejestracji
ECC	rozszerzony współczynnik korelacji (ang. *enhanced correlation coefficient*)
FLE	błąd lokalizacji znacznika (ang. *fiducial localization error*)
FPN	piramidalna sieć cech (ang. *Feature Pyramid Network*)
FRE	błąd dopasowania znaczników (ang. *fiducial registration error*)
GPU	procesor graficzny (ang. *graphics processing unit*)
HD95	95. percentyl odległości Hausdorffa (ang. *95th percentile Hausdorff distance*)
HEIC	format zapisu zdjęć (ang. *High Efficiency Image Container*)
HTML	język znaczników dokumentów internetowych (ang. *HyperText Markup Language*)
IoU	indeks Jaccarda – iloraz części wspólnej i sumy obszarów (ang. *intersection over union*)
ISBI	międzynarodowe sympozjum obrazowania biomedycznego (ang. *International Symposium on Biomedical Imaging*)
ISIC	międzynarodowa współpraca w zakresie obrazowania skóry (ang. *International Skin Imaging Collaboration*)
JAC	indeks Jaccarda (ang. *Jaccard index*)
JPG	format stratnej kompresji obrazów (ang. *Joint Photographic Experts Group*)
JSON	tekstowy format wymiany danych (ang. *JavaScript Object Notation*)
M1	model segmentacji znamienia na zdjęciu (PanDerm z dekoderem UperNet)
M3	model segmentacji znacznika na obrazie termowizyjnym (U-Net)
MI	informacja wzajemna (ang. *mutual information*)
MR	rezonans magnetyczny (ang. *magnetic resonance*)
NIR	bliska podczerwień (ang. *near infrared*)
NMI	znormalizowana informacja wzajemna (ang. *normalized mutual information*)
OECD	Organizacja Współpracy Gospodarczej i Rozwoju (ang. *Organisation for Economic Co-operation and Development*)
ONNX	otwarty format zapisu modeli sieci neuronowych (ang. *Open Neural Network Exchange*)
PNG	format bezstratnej kompresji obrazów (ang. *Portable Network Graphics*)
PPM	moduł łączenia piramidalnego (ang. *Pyramid Pooling Module*)
PU	przypadek użycia
ReLU	funkcja aktywacji – jednostka liniowa z obcięciem (ang. *rectified linear unit*)
RGB	model barw: czerwony, zielony, niebieski; w pracy – zdjęcie w świetle widzialnym (ang. *red, green, blue*)
ROI	obszar zainteresowania (ang. *region of interest*)
SEQ	format nagrań kamer termowizyjnych FLIR (sekwencja klatek z danymi radiometrycznymi)
SQL	strukturalny język zapytań (ang. *Structured Query Language*)
SSIM	indeks podobieństwa strukturalnego (ang. *structural similarity index*)
SURF	przyspieszone odporne cechy (ang. *Speeded-Up Robust Features*)
T01–T18	testy funkcjonalne systemu
TG1–TG6	testy interfejsu graficznego
TH	obraz termowizyjny (ang. *thermal*)
TRE	błąd w punkcie docelowym (ang. *target registration error*)

TRUS	ultrasonografia przezodbytnicza (ang. *transrectal ultrasound*)
UML	ujednolicony język modelowania (ang. *Unified Modeling Language*)
ViT	transformer wizyjny (ang. *Vision Transformer*); ViT-L – wariant duży
VIS	światło widzialne (ang. *visible*)
WF	wymaganie funkcjonalne
WN	wymaganie pozafunkcjonalne

Rozdział 1

Wstęp

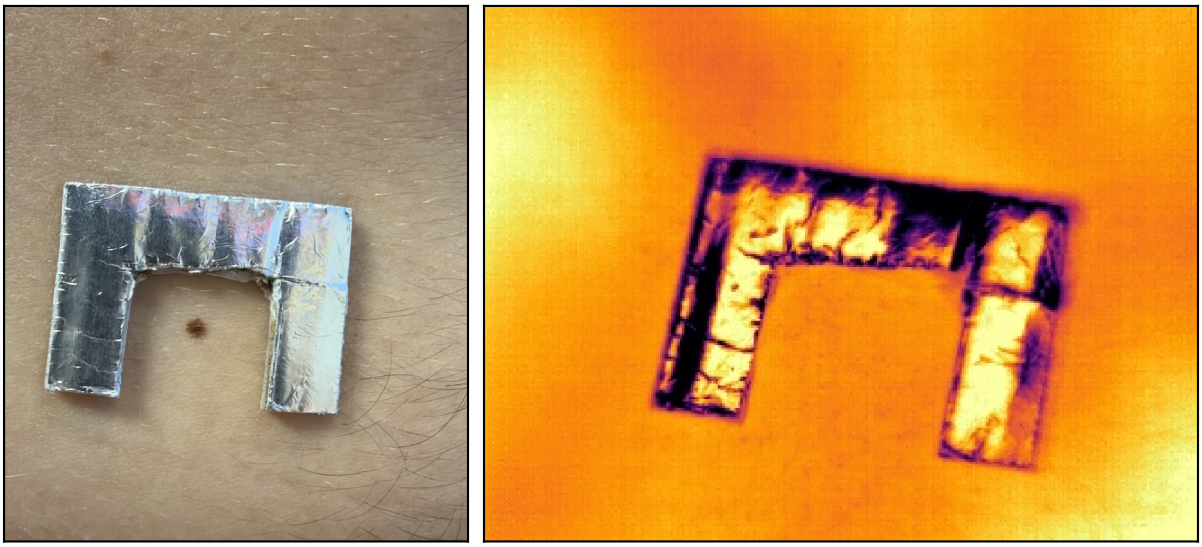
1.1 Motywacja

Czerniak jest jednym z najgroźniejszych nowotworów skóry, a jego wczesne wykrycie decyduje o skuteczności leczenia. W ocenie zmian barwnikowych podstawową rolę odgrywa obraz w świetle widzialnym – zdjęcie kliniczne lub obraz dermatoskopowy – na którym ocenia się kształt, brzeg i barwę zmiany [1]. Obraz taki nie niesie jednak informacji o procesach fizjologicznych zachodzących w zmianie.

Informację tę może uzupełnić termografia, czyli rejestracja promieniowania podczerwonego emitowanego przez skórę. Skóra zachowuje się niemal jak ciało doskonale czarne o emisyjności 0,96–0,98, dzięki czemu termogram odwzorowuje rozkład temperatury jej powierzchni [15]. Zmiany nowotworowe mogą różnić się od otoczenia odpowiedzią termiczną, zwłaszcza po kontrolowanym schłodzeniu skóry [8, 10]. Obraz widzialny i obraz termowizyjny mają więc charakter komplementarny: pierwszy zawiera bogatą teksturę, drugi – informację termiczną, ubogą jednak w szczegóły [22].

Warunkiem wspólnej analizy obu obrazów jest ich rejestracja, czyli sprowadzenie do wspólnego układu współrzędnych. W rozważanym zastosowaniu zadanie to jest trudne z trzech powodów. Po pierwsze, zdjęcie wykonuje się telefonem, a termogram – osobną kamerą termowizyjną; urządzenia nie są ze sobą sprzężone, różnią się polem widzenia i rozdzielczością (obraz termowizyjny ma 320×240 pikseli), a każda para obrazów powstaje z innej odległości i pod innym kątem. Po drugie, intensywności pikseli w obrazie widzialnym i podczerwonym nie są ze sobą bezpośrednio powiązane, przez co zawodzą klasyczne metody oparte na punktach charakterystycznych [7]; dokładne wyrównanie par obrazów widzialnych i podczerwonych pozostaje problemem otwartym [22]. Po trzecie, znamię bez schłodzenia skóry nie jest widoczne na termogramie [8], nie może więc samo służyć jako punkt odniesienia (rys. 1.1).

Dodatkowym problemem jest weryfikacja wyniku. Nawet poprawnie wyglądające nałożenie obrazów nie gwarantuje, że obszar wyznaczony na zdjęciu odpowiada temu samemu fragmentowi skóry na termogramie. Ręczne oznaczanie punktów kontrolnych w każdej parze obrazów jest pracochłonne, dlatego pożądane jest rozwiązanie, które ocenia zgodność wyznaczenia obszaru automatycznie. Powyższe obserwacje stanowią motywację do podjęcia niniejszej pracy.



Rysunek 1.1: Zmiana skórna z naklejonym znacznikiem Π: a) zdjęcie wykonane telefonem, b) obraz termowizyjny 320 × 240 pikseli. Znamię, widoczne na zdjęciu między ramionami znacznika, nie jest widoczne na termogramie. Źródło: opracowanie własne

1.2 Cel i zakres pracy

Celem pracy jest opracowanie, implementacja oraz ocena systemu informatycznego umożliwiającego rejestrację i wspólną analizę obrazów dermatologicznych pochodzących z dwóch modalności: zdjęcia RGB wykonanego telefonem oraz obrazu termowizyjnego. System sprowadza oba obrazy do wspólnej przestrzeni odniesienia, przenosi obszar zainteresowania (ang. *region of interest*, ROI) między modalnościami i wyznacza jego parametry ilościowe. Zgodność wyznaczenia tego samego obszaru w obu modalnościach system weryfikuje, porównując maski segmentacji uzyskane modelami dedykowanymi każdej modalności, a wynikiem jest raport zawierający miary zgodności masek.

Aby osiągnąć ten cel, zrealizowano następujące zadania:

1. przegląd literatury dotyczącej rejestracji obrazów wielomodalnych, segmentacji obrazów medycznych oraz miar oceny obu procesów;
2. analizę wymagań i projekt systemu, obejmujący przypadki użycia, architekturę, diagram klas, bazę danych SQLite oraz interfejs użytkownika;
3. zaprojektowanie znacznika referencyjnego w kształcie litery Π (35 × 26 mm, szerokość paska 9 mm, otwór 17 × 17 mm), widocznego w obu modalnościach;
4. zebranie własnego zbioru danych: 94 par zdjęcie–termogram przedstawiających 34 znamiona, wraz z ręcznymi adnotacjami wykonanymi w programie CVAT;
5. implementację modułu rejestracji opartego na automatycznej detekcji znacznika i maksymalizacji rozszerzonego współczynnika korelacji (ECC);
6. przygotowanie modeli segmentacji dla obu modalności: modelu PanDerm z dekoderem UperNet do segmentacji znamienia na zdjęciu oraz sieci U-Net do segmentacji znacznika na obrazie termowizyjnym;

7. implementację przeniesienia ROI, pomiarów w milimetrach, miar zgodności masek oraz zapisu współrzędnych i surowej intensywności pikseli obrazu termowizyjnego w obszarze znamienia;

8. implementację aplikacji z interfejsem graficznym, przetwarzania wsadowego i raportowania wyników;

9. weryfikację systemu, obejmującą ocenę dokładności rejestracji, zgodności masek między modalnościami oraz jakości segmentacji;

10. przygotowanie dokumentacji technicznej i instrukcji użytkownika.

Zakres pracy nie obejmuje diagnostyki ani klasyfikacji zmian skórnych – system nie stanowi narzędzia diagnostycznego. System zapisuje surowe intensywności pikseli obrazu termowizyjnego w obszarze znamienia, ale nie przelicza ich na temperaturę ani ich nie interpretuje; termografia dynamiczna stanowi jedynie kontekst rozważań. Ponieważ znamię nie jest widoczne na termogramie, obszarem porównywanym między modalnościami jest otwór znacznika referencyjnego, w którym znajduje się znamię. Badania przeprowadzono na danych zebranych jednym zestawem urządzeń.

Wkład własny autora obejmuje projekt znacznika, zebranie i opisanie zbioru danych, metodę rejestracji opartą na maskach znacznika, douczenie i trening modeli segmentacji, badania weryfikacyjne oraz implementację aplikacji i bazy danych. W pracy wykorzystano gotowy koder modelu PanDerm udostępniony przez jego autorów [21] oraz biblioteki programistyczne wymienione w rozdziale 4.

1.3 Struktura pracy

Praca składa się z siedmiu rozdziałów oraz dwóch dodatków. W rozdziale 2 przedstawiono przegląd literatury dotyczącej obrazowania zmian skórnych, rejestracji obrazów wielomodalnych, segmentacji oraz miar oceny. Rozdział 3 zawiera analizę projektową: założenia, wymagania, przypadki użycia i architekturę systemu. W rozdziale 4 opisano projekt systemu, w tym dobór technologii, projekt znacznika referencyjnego, bazy danych, diagram klas i interfejs użytkownika. Rozdział 5 przedstawia implementację poszczególnych modułów, a rozdział 6 – wyniki badań weryfikacyjnych. Pracę zamyka podsumowanie wraz z kierunkami dalszych prac. Dodatek A zawiera instrukcję użytkownika, a Dodatek B – dokumentację techniczną.

Rozdział 2

Analiza stanu wiedzy

W rozdziale omówiono kolejno: obrazowanie zmian skórnych w świetle widzialnym i w podczerwieni, metody rejestracji obrazów wielomodalnych, segmentację obrazów medycznych oraz miary oceny rejestracji i segmentacji. Rozdział zamyka zestawienie prac najbliższych tematowi i wskazanie luki, którą wypełnia niniejsza praca.

2.1 Obrazowanie zmian skórnych

Podstawą oceny zmian barwnikowych jest obraz w świetle widzialnym. Dermatoskopia ogranicza odbicie światła od powierzchni skóry i uwidacznia struktury niewidoczne gołym okiem, a komputerowa analiza obrazów dermatoskopowych obejmuje segmentację zmiany, ekstrakcję cech i klasyfikację [1]. Segmentacja jest pierwszym, a zarazem trudnym etapem tej analizy: utrudniają ją zmienność kształtu, rozmiaru i barwy zmian, włosy, naczynia oraz niejednolite warunki akwizycji [1]. Celebi i in. [1] zwracają uwagę, że metody sztucznej inteligencji można stosować także do zwykłych zdjęć wykonywanych z bliska, które dobrze oddają teksturę powierzchni skóry.

Termografia rejestruje promieniowanie podczerwone emitowane przez skórę. Emisyjność skóry wynosi 0,96–0,98, a maksimum jej emisji przypada na zakres 9–12 µm [15]. Termogram przedstawia wyłącznie rozkład temperatury powierzchni, a wiarygodność pomiaru zależy od standaryzacji badania, w tym od powtarzalnego wyznaczania obszaru zainteresowania – jego kształt, rozmiar i położenie wpływają na wynik diagnostyczny [15].

W termografii statycznej obraz rejestruje się bez stymulacji, a w dynamicznej – po bodźcu termicznym, chemicznym lub mechanicznym [10]. Herman i Pirtini Cetingul [8] chłodzą zmianę wraz z otoczeniem o średnicy 50 mm strumieniem zimnego powietrza przez 1 min, a następnie co 2 s rejestrują powrót temperatury trwający 3–4 min. Ponieważ bez schłodzenia zmiana jest niewidoczna na termogramie, wokół niej przykleja się kwadratowy znacznik, którego narożniki służą do rejestracji zdjęcia z sekwencją obrazów w podczerwieni. Magalhaes i in. [10] porównali termografię statyczną i dynamiczną dla 46 zmian (16 czerniaków i 30 znamion) zarejestrowanych kamerą o rozdzielczości 320 × 240 pikseli; najlepszy klasyfikator, wykorzystujący cechy statyczne, osiągnął dokładność 84,2% przy czułości 91,3%. Obszar analizy wyznaczano tam ręcznie jako okno 40 × 40 pikseli umieszczane przez użytkownika.

Obraz widzialny i obraz podczerwony są komplementarne: pierwszy ma bogatą teksturę, lecz zależy od oświetlenia, drugi niesie informację termiczną niezależną od oświetlenia, ale ubogą w szczegóły [22]. Łączenie obu modalności wymaga jednak ich wcześniejszej rejestracji, omówionej w kolejnym podrozdziale.

2.2 Rejestracja obrazów wielomodalnych

2.2.1 Modele transformacji i miary podobieństwa

Rejestracja obrazów to proces nakładania dwóch lub więcej obrazów tej samej sceny wykonanych w różnym czasie, z różnych punktów widzenia lub różnymi sensorami, czyli geometryczne dopasowanie obrazu rejestrowanego do obrazu referencyjnego [23]. Zitová i Flusser [23] opisują ją czterema etapami: detekcją cech, dopasowaniem cech, estymacją modelu transformacji oraz transformacją i przepróbkowaniem obrazu (rys. 2.1). Metody dzieli się na obszarowe (ang. *area-based*), porównujące bezpośrednio intensywności, oraz oparte na cechach (ang. *feature-based*). Metody obszarowe wymagają, aby intensywności obu obrazów były identyczne albo przynajmniej statystycznie zależne, natomiast metody oparte na cechach nadają się do rejestracji obrazów z różnych sensorów [23].

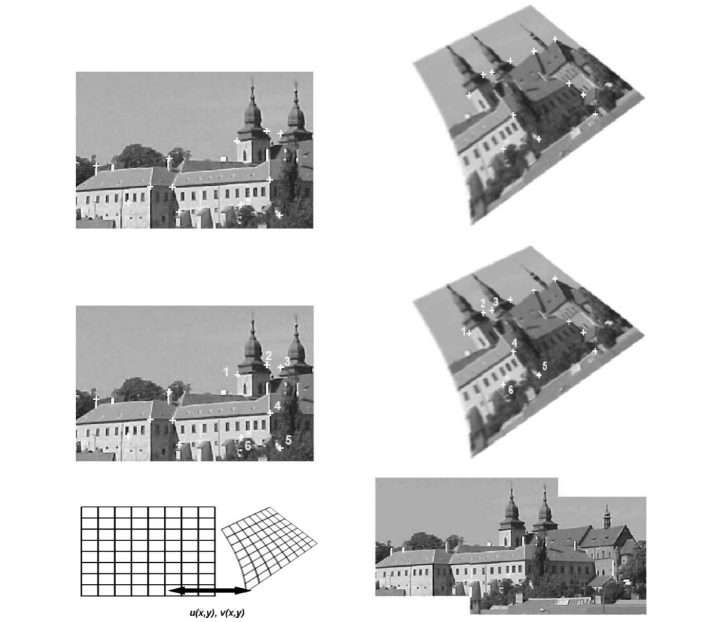


Fig. 1. Four steps of image registration: top row—feature detection (corners were used as the features in this case). Middle row—feature matching by invariant descriptors (the corresponding pairs are marked by numbers). Bottom left—transform model estimation exploiting the established correspondence. Bottom right—image resampling and transformation using appropriate interpolation technique.

Rysunek 2.1: Etapy rejestracji obrazów: detekcja cech (u góry), dopasowanie cech (w środku), estymacja modelu transformacji (na dole po lewej) oraz przepróbkowanie obrazu (na dole po prawej). Źródło: [23]

Wybór modelu transformacji określa, jakie zniekształcenia mogą zostać skompensowane. Model podobieństwa (obrót, przesunięcie, jednolita skala) wyznaczają dwa punkty kontrolne, model afiniczny – trzy niewspółliniowe punkty; zachowuje on proste i równoległość. Przekształcenie perspektywiczne (homografia) dokładnie opisuje płaską scenę fotografowaną kamerą, której oś optyczna nie jest prostopadła do sceny, i wymaga czterech punktów kontrolnych [23]. W pracy [6] homografia, mimo największej liczby stopni swobody, najsłabiej przenosiła się na obrazy wykonane w innej odległości niż obrazy, na których ją wyznaczono. Oniga i in. [14] uzasadniają z kolei wybór homografii tym, że niewielki fragment skóry ze sztywnym znacznikiem jest lokalnie quasi-płaski.

W metodach obszarowych transformację wyznacza się przez optymalizację miary podobieństwa. Evangelidis i Psarakis [4] zaproponowali kryterium rozszerzonego współczynnika korelacji (ang. *enhanced correlation coefficient*, ECC), które – dzięki odjęciu średniej i normalizacji

wektorów intensywności – jest niezmiennicze względem zmian jasności i kontrastu. Kryterium jest nieliniowe względem parametrów, dlatego autorzy zaproponowali iteracyjne schematy optymalizacji z rozwiązaniem w postaci zamkniętej w każdej iteracji; w eksperymentach symulacyjnych osiągały one mniejszy błąd i częstszą zbieżność niż odpowiadające im warianty algorytmu Lucasa–Kanade [4]. Jak wszystkie metody gradientowe, ECC wymaga jednak dobrego punktu startowego i ma trudności w obszarach jednorodnych oraz przy dużych przesunięciach [4]. W rejestracji wielomodalnej stosuje się miary statystyczne, przede wszystkim informację wzajemną [23], która nie zakłada postaci zależności między intensywnościami; Roche i in. [16] pokazali jednak na przykładzie syntetycznym, że może ona mieć wiele równoważnych maksimów.

W niniejszej pracy miarę podobieństwa oblicza się nie na surowych obrazach, lecz na maskach znacznika wyodrębnionych w obu modalnościach, co sprowadza problem wielomodalny do jednomodalnego i umożliwia zastosowanie kryterium ECC.

2.2.2 Rejestracja obrazów widzialnych i termowizyjnych

Rejestrację obrazów widzialnych i termowizyjnych utrudnia odmienny mechanizm ich powstawania: jasność w podczerwieni zależy od temperatury i emisyjności obiektów, a w świetle widzialnym – od światła odbitego, więc intensywności nie są bezpośrednio powiązane [7]. Han i in. [7] wykazali, że punkty charakterystyczne SURF i Harrisa wykrywane w obu modalnościach w dużej mierze się nie pokrywają. Zaproponowana przez nich metoda wykorzystuje proste wyprowadzone z krawędzi obiektów, przez co wymaga struktur typowych dla otoczenia zbudowanego przez człowieka i nie przenosi się na obrazy skóry.

W zastosowaniach medycznych korespondencję zapewnia się zwykle obiektem widocznym w obu modalnościach. González-Pérez i in. [6] porównali cztery metody rejestracji obrazów stopy w systemie z kamerami połączonymi na sztywno; punkty kalibracyjne dawała szachownica umieszczona przed schłodzoną płytą aluminiową, kontrastującą termicznie z otoczeniem. Metoda afiniczna optymalizowana na binarnych maskach stóp uzyskała w płaszczyźnie ostrości kamer (800 mm) współczynnik Dice'a 0,982, przy czym na surowych obrazach różnych widm optymalizacja ta nie zbiegała poprawnie [6]. Maurya i in. [12] wyznaczają punkty kontrolne na ramie kalibracyjnej wyciętej z materiału słabo przewodzącego ciepło, a transformację doprecyzowują cechami opartymi na zgodności fazy, uzyskując średni błąd rejestracji 1,817 piksela dla 50 par obrazów. Obszar zainteresowania wyznaczają i śledzą w obrazie RGB, a następnie przenoszą go na obraz termowizyjny, ubogi w teksturę [12].

Najbliższe tematowi niniejszej pracy jest rozwiązanie Onigi i in. [14], którzy rejestrują obrazy zmian skórnych w świetle widzialnym, bliskiej podczerwieni i termowizji z użyciem kwadratowego znacznika umieszczonego na skórze wokół zmiany (rys. 2.2). Znacznik lokalizuje detektor YOLOv8n, a homografię wyznacza się z punktów kluczowych przewidywanych przez sieć neuronową. Autorzy zauważają, że w obrazie termowizyjnym znacznik bywa słabiej widoczny i ma zaokrąglone narożniki, a zmiana skórna często nie jest widoczna. Wyniki oceniano wyłącznie miarami podobieństwa obrazów (SSIM, MI, NMI), bez miar geometrycznych [14].

2.2.3 Metody oparte na uczeniu głębokim

Przegląd Chena i in. [2], obejmujący 77 prac, dzieli metody głębokiej rejestracji obrazów medycznych na trzy grupy: sieci pełniące rolę miary podobieństwa, sieci bezpośrednio

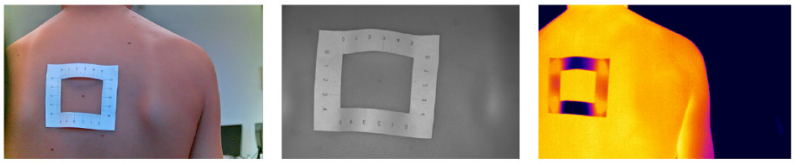


FIGURE 3
Acquired image triplet: VIS image (**left**), NIR image (**middle**), and TH image (**right**).

Rysunek 2.2: Kwadratowy znacznik referencyjny na skórze w obrazie widzialnym (po lewej), w bliskiej podczerwieni (w środku) i w obrazie termowizyjnym (po prawej). Źródło: [14]

wyznaczające parametry transformacji (w wariantach nadzorowanym, słabo nadzorowanym i nienadzorowanym) oraz pozostałe zastosowania. Przykładem podejścia słabo nadzorowanego jest praca Hu i in. [9], w której sieć konwolucyjna przewiduje pole przemieszczeń między obrazami MR i TRUS prostaty; etykiety anatomiczne są potrzebne wyłącznie podczas uczenia, a w fazie wnioskowania wystarcza para obrazów. Autorzy uzyskali medianę błędu w punktach docelowych 3,6 mm na 108 parach obrazów, podczas gdy klasyczna rejestracja oparta na miarach intensywności zawiodła na tych danych [9]. Metody głębokie wymagają jednak licznych danych uczących, a publicznie dostępnych zbiorów wielomodalnych jest niewiele [2]. Dla pary telefon–kamera termowizyjna takich danych nie ma, dlatego w niniejszej pracy zastosowano rejestrację klasyczną opartą na znaczniku.

2.2.4 Fuzja i wizualizacja nałożenia

Zhang i Demiris [22] wyróżniają fuzję obrazów widzialnych i podczerwonych na poziomie pikseli, cech i decyzji; w literaturze termin ten odnosi się zwykle do poziomu pikseli, na którym powstaje jeden obraz wynikowy. Fuzja pikselowa wymaga dokładnej rejestracji, a autorzy uznają wyrównanie obrazów widzialnych i podczerwonych za problem otwarty, wskazując wspólne uczenie rejestracji i fuzji jako kierunek badań [22]. W niniejszej pracy nałożenie obrazów pełni funkcję wizualizacji wyniku rejestracji, a wspólna analiza odbywa się przez przeniesienie obszaru zainteresowania, podobnie jak w [12].

2.3 Segmentacja obrazów medycznych

2.3.1 Metody klasyczne

Przed upowszechnieniem uczenia głębokiego segmentację zmian skórnych realizowano m.in. progowaniem adaptacyjnym, konturami aktywnymi, rozrostem obszaru i klasteryzacją (za: [13]). Metody te opierają się na cechach projektowanych ręcznie, co ogranicza ich skuteczność na dużych i zróżnicowanych zbiorach danych [13]. W niniejszej pracy metody klasyczne wykorzystano do detekcji znacznika referencyjnego, który ma znany kształt i wyraźnie kontrastuje ze skórą.

2.3.2 Sieć U-Net i architektury koder–dekoder

Ronneberger i in. [17] zaproponowali sieć U-Net do segmentacji obrazów biomedycznych przy bardzo małej liczbie oznaczonych obrazów. Ścieżka kurcząca (koder) gromadzi kontekst, symetryczna ścieżka rozszerzająca (dekoder) zapewnia dokładną lokalizację,

a połączenia skrótowe przekazują cechy wysokiej rozdzielczości z kodera do dekodera (rys. 2.3). Kluczowym elementem uczenia była intensywna augmentacja, zwłaszcza losowe deformacje sprężyste; sieć uczona na 30 obrazach z mikroskopii elektronowej zajęła pierwsze miejsce w rankingu wyzwania ISBI według błędu deformacji [17]. Według przeglądu [13], obejmującego 177 prac o segmentacji zmian skórnych, połączenia skrótowe stosuje 112 z nich, a najczęstszymi funkcjami straty są entropia krzyżowa i strata Dice.

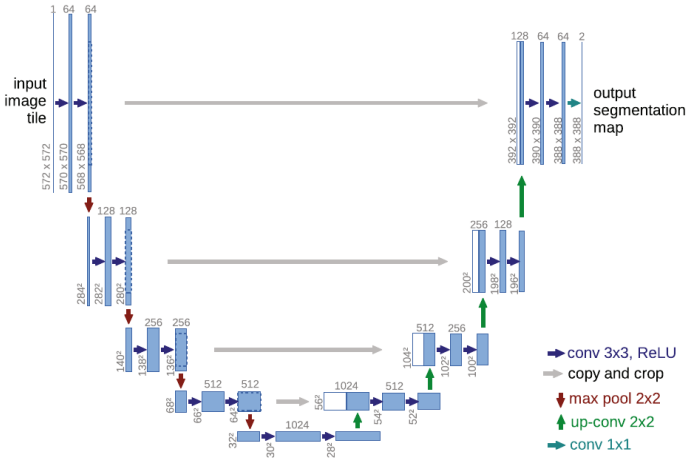


Fig. 1. U-net architecture (example for 32x32 pixels in the lowest resolution). Each blue box corresponds to a multi-channel feature map. The number of channels is denoted on top of the box. The x-y-size is provided at the lower left edge of the box. White boxes represent copied feature maps. The arrows denote the different operations.

Rysunek 2.3: Architektura sieci U-Net. Prostokąty oznaczają mapy cech (nad nimi liczba kanałów), strzałki – operacje. Źródło: [17]

Dekoder UperNet [20] łączy piramidę cech (ang. *Feature Pyramid Network*, FPN) z modułem łączenia piramidalnego (ang. *Pyramid Pooling Module*, PPM) dołączonym do najgłębszej warstwy kodera. Moduł PPM wnosi kontekst globalny, a fuzja map cech ze wszystkich poziomów piramidy poprawia wynik segmentacji; w oryginalnej pracy na zbiorze ADE20K konfiguracja FPN + PPM z fuzją osiągnęła mIoU 41,22% [20].

2.3.3 Modele bazowe w dermatologii i zbiory danych

Model bazowy (ang. *foundation model*) to duża sieć wstępnie uczona samonadzorowanie na dużym, zróżnicowanym zbiorze danych, którą można douczyć do konkretnego zadania przy niewielkiej liczbie etykiet [21]. PanDerm [21] to model bazowy dla dermatologii z koderem typu ViT-Large, uczony na 2 149 706 obrazach z 11 źródeł w czterech modalnościach: fotografii całego ciała, dermatopatologii, zdjęciach klinicznych (460 328 obrazów) i obrazach dermatoskopowych. W zadaniu segmentacji, z dekoderem UperNet, model uzyskał Dice 0,910 na zbiorze ISIC 2018 i 0,949 na HAM10000, przewyższając modele porównawcze (tab. 2.1); przy 5% danych uczących dorównywał najlepszemu z pozostałych modeli uczonych na pełnym zbiorze [21]. Segmentację oceniono jednak wyłącznie na obrazach dermatoskopowych.

Najczęściej wykorzystywanymi zbiorami do segmentacji zmian skórnych są zbiory wyzwań ISIC, użyte w 168 ze 177 prac objętych przeglądem [13]. Zbiór zadania segmentacji ISIC 2018 obejmuje 3694 obrazy dermatoskopowe z oficjalnym podziałem na 2594 obrazy uczące, 100 walidacyjnych i 1000 testowych [3, 13]. Zbiór HAM10000 [19] zawiera 10 015 obrazów dermatoskopowych z dwóch ośrodków, zebranych w ciągu 20 lat i przypisanych

Tablica 2.1: Wyniki segmentacji zmian skórnych modelu PanDerm i modeli porównawczych (DSC – współczynnik Dice'a, JAC – indeks Jaccarda). Opracowanie własne na podstawie [21]

Model	ISIC 2018		HAM10000	
	DSC	JAC	DSC	JAC
SL-ImageNet	0,876	0,807	0,927	0,875
autoSMIM	0,848	0,769	0,920	0,865
BATFormer	0,884	0,815	0,937	0,891
PanDerm	**0,910**	**0,846**	**0,949**	**0,910**

do siedmiu klas diagnostycznych. W wyzwaniu ISIC 2018 wprowadzono progowany indeks Jaccarda, w którym wynik dla obrazu poniżej 0,65 zastępuje się zerem, traktując segmentację jako porażkę; próg wyznaczono na podstawie zgodności trzech ekspertów, których średni indeks Jaccarda wynosił 0,786 [3]. Problem segmentacji pozostaje otwarty – najlepsze zgłoszenie uzyskało progowany indeks Jaccarda 0,802, a mimo średnich wartości indeksu Jaccarda powyżej 0,8 większość metod zawodziła na ponad 10% obrazów, najczęściej w przypadku rogowacenia łojotokowego [3]. Jednocześnie liczba zdjęć klinicznych z maskami segmentacji od lat pozostaje niewielka w porównaniu z obrazami dermatoskopowymi [13], dlatego modele uczone na dermoskopii stosowane do zdjęć z telefonu pracują w warunkach przesunięcia dziedziny (ang. *domain shift*).

2.3.4 Segmentacja obrazów termowizyjnych

Ponieważ znamię bez schłodzenia skóry nie jest widoczne na termogramie, w pracach dotyczących termografii zmian skórnych obrys wyznacza się na obrazie widzialnym i przenosi na obraz w podczerwieni [8] albo obszar analizy ustawia się ręcznie [10]. W termowizji można natomiast wyznaczyć obiekt referencyjny o odmiennych własnościach termicznych – znacznik [14]. Z tego względu w niniejszej pracy model segmentacji dedykowany termowizji wyznacza maskę znacznika, a nie znamienia.

2.4 Miary oceny rejestracji i segmentacji

Fitzpatrick i in. [5] rozróżniają trzy rodzaje błędów rejestracji opartej na punktach: błąd lokalizacji znacznika (ang. *fiducial localization error*, FLE), błąd dopasowania znaczników po rejestracji (ang. *fiducial registration error*, FRE) oraz błąd w punkcie docelowym (ang. *target registration error*, TRE), czyli odległość między odpowiadającymi sobie punktami po rejestracji. Autorzy wykazali, że FRE nie zależy od konfiguracji znaczników i jest zawodnym wskaźnikiem dokładności, natomiast TRE rośnie wraz z odległością celu od środka konfiguracji [5]. Dokładność rejestracji należy więc oceniać na punktach, które nie uczestniczyły w wyznaczaniu transformacji; zdaniem Zitovej i Flussera [23] bez oceny ilościowej żadna metoda rejestracji nie może zostać przyjęta do praktycznego zastosowania.

Taha i Hanbury [18] zestawili 20 miar oceny segmentacji w sześciu kategoriach, m.in. miary pokrycia, objętościowe i odległościowe. Współczynnik Dice'a i indeks Jaccarda są ze sobą powiązane monotonicznie, dlatego dają ten sam ranking segmentacji. Miary pokrycia nie wykrywają błędów kształtu brzegu (rys. 2.4) i nie są zalecane dla małych obiektów, a odległość Hausdorffa jest wrażliwa na punkty odstające, dlatego zastępuje się

ją kwantylem odległości [18]. Zgodnie z zaleceniami Metrics Reloaded [11], opracowanymi w procesie delfickim przez międzynarodowe konsorcjum ekspertów, w segmentacji semantycznej miarę pokrycia (DSC lub IoU) uzupełnia się miarą brzegową, np. 95. percentylem odległości Hausdorffa (HD95) lub średnią symetryczną odległością powierzchni (ASSD). Te same zalecenia wskazują, że miary należy liczyć osobno dla każdego obrazu i agregować z uwzględnieniem hierarchii danych [11]. Podobne podejście – ocenę rejestracji przez zgodność masek po przeniesieniu – zastosowano w pracy [6].

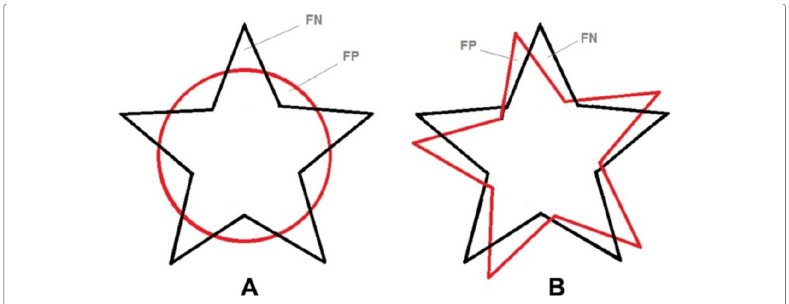


Fig. 6 Metrics that fail to discover boundary errors. In **a**, the star is compared with a circle and in **b** the same star is compared with another star of the same dimensions, rotated so that the resulting overlap errors (FP and FN) are equal in magnitude in both cases. All metrics that are based on FP and FN (overlap-based metrics) are not able to discover that the two shapes in (**b**) are more similar to each other than those in (**a**). On the contrary, all spatial distance based metrics discover the similarity and give (**b**) a higher score than (**a**). However, the metric most invariant to boundary error is the volumetric similarity, since it gives a perfect match in both cases

Rysunek 2.4: Przykład, w którym miary pokrycia nie wykrywają błędu brzegu: w obu przypadkach liczby pikseli fałszywie dodatnich i fałszywie ujemnych są równe, mimo różnego podobieństwa kształtów. Źródło: [18]

W niniejszej pracy dokładność rejestracji oceniano błędem TRE wyznaczanym na narożnikach znacznika oznaczonych ręcznie, które nie uczestniczą w wyznaczaniu transformacji, a zgodność masek – współczynnikiem Dice'a uzupełnionym miarami HD95 i ASSD wyrażonymi w milimetrach.

2.5 Podsumowanie i luka badawcza

Zestawienie prac rejestrujących obraz widzialny z termowizyjnym przedstawiono w tabeli 2.2. We wszystkich rozwiązaniach przeznaczonych dla medycyny korespondencję między modalnościami zapewnia obiekt referencyjny, a obszar zainteresowania wyznacza się w obrazie widzialnym. Prace różnią się jednak sposobem oceny: stosowano błąd w pikselach, zgodność masek albo miary podobieństwa obrazów, a w żadnej z nich nie weryfikowano zgodności przeniesionego obszaru niezależnym modelem segmentacji drugiej modalności.

Z przeglądu wynikają trzy wnioski dla projektu systemu. Po pierwsze, ze względu na brak wspólnych cech naturalnych i niewidoczność znamienia na termogramie korespondencję należy oprzeć na znaczniku widocznym w obu modalnościach. Po drugie, brak dużego zbioru par telefon–termogram przemawia za klasyczną rejestracją na maskach znacznika, a w segmentacji – za douczaniem modelu bazowego i niewielkimi sieciami typu U-Net. Po trzecie, ocena powinna łączyć błąd w punktach docelowych z miarami pokrycia i miarami brzegowymi. W przeanalizowanej literaturze nie znaleziono systemu, który rejestruje zdjęcie z telefonu z termogramem na podstawie znacznika o znanym kształcie i weryfikuje zgodność przeniesionego obszaru modelem segmentacji dedykowanym drugiej modalności, bez potrzeby ręcznych adnotacji. Lukę tę wypełnia niniejsza praca.

Tablica 2.2: Prace rejestrujące obraz widzialny z obrazem termowizyjnym. Opracowanie własne na podstawie [8, 7, 12, 6, 14]

Praca	Zastosowanie	Źródło korespondencji	Ocena rejestracji
Herman i Pirtini	termografia dynamiczna zmian	narożniki kwadratowego	brak miar ilościowych
Cetingul [8]	barwnikowych	znacznika na skórze	
Han i in. [7]	sceny zurbanizowane	proste z krawędzi obiektów, punkty Harrisa	błąd w pikselach
Maurya i in. [12]	pomiar częstości oddechu	rama kalibracyjna, cechy zgodności fazy	TRE 1,817 piksela (50 par)
González-Pérez i in. [6]	monitorowanie stopy cukrzycowej	szachownica z płytą aluminiową, maski stóp	Dice i Jaccard masek
Oniga i in. [14]	zmiany skórne (VIS, NIR, TH)	kwadratowy znacznik, punkty z sieci neuronowej	SSIM, MI, NMI
Niniejsza praca	zmiany skórne	kształt znacznika II (maski w obu modalnościach)	TRE w mm, zgodność masek z modelu segmentacji termowizji

Rozdział 3

Analiza projektowa

W rozdziale przedstawiono założenia, przy których projektowano system, wymagania funkcjonalne i pozafunkcjonalne, przypadki użycia oraz architekturę systemu. Opisano tu, *co* system ma realizować; sposób realizacji omówiono w rozdziale 4.

3.1 Założenia i ograniczenia

System jest przeznaczony dla studentów i lekarzy współpracujących z Uniwersyteckim Centrum Klinicznym w Gdańsku. Przy jego projektowaniu przyjęto następujące założenia:

- danymi wejściowymi są dwa obrazy tej samej zmiany: zdjęcie RGB wykonane telefonem (format JPG) oraz obraz termowizyjny o rozdzielczości 320×240 pikseli, wyodrębniony z nagrania kamery termowizyjnej FLIR A320 z obiektywem 18 mm (format .SEQ);
- obrazy pochodzą z dwóch niezależnych urządzeń, niesprzężonych i nieskalibrowanych względem siebie, a każde zdjęcie wykonywane jest z innej odległości i pod innym kątem – transformację między obrazami należy więc wyznaczać osobno dla każdej pary;
- na skórze wokół zmiany nakleja się znacznik referencyjny w kształcie litery Π, a znamię znajduje się między jego ramionami; przyjęto, że skóra w obrębie znacznika jest w przybliżeniu płaska, dzięki czemu zależność między obrazami opisuje przekształcenie afiniczne lub homografia;
- znamię nie jest widoczne na obrazie termowizyjnym, dlatego w tej modalności segmentuje się znacznik, a obszarem porównywanym między modalnościami jest otwór znacznika;
- system działa w pełni automatycznie; ręczne adnotacje wykonane w programie CVAT służą wyłącznie do oceny wyników;
- system działa lokalnie na komputerze z systemem Windows; model segmentacji znamienia wymaga osobnego środowiska z biblioteką PyTorch; procesor graficzny przyspiesza jego działanie, ale nie jest wymagany.

Poza zakresem systemu pozostają diagnostyka zmian skórnych, analiza temperatury, praca w czasie rzeczywistym oraz praca wielu użytkowników jednocześnie. System nie stanowi narzędzia diagnostycznego; jego zadaniem jest dostarczenie spójnych przestrzennie danych z obu modalności oraz ocena wiarygodności ich zestawienia.

3.2 Wymagania funkcjonalne

Wymagania funkcjonalne, pogrupowane według etapów przetwarzania, zestawiono w tabeli 3.1. Priorytet określono w skali: *wymagane* (W) i *pożądane* (P).

Tablica 3.1: Wymagania funkcjonalne systemu

ID	System umożliwia	Priorytet
WF1	wczytanie pary obrazów ze zbioru (numer pary) albo dwóch dowolnych plików	W
WF2	automatyczną rejestrację: wykrycie znacznika w obu modalnościach i wyznaczenie macierzy transformacji T	W
WF3	podgląd nałożenia obrazów z regulowaną przezroczystością i zapis nałożenia	W
WF4	wyznaczenie ośmiu narożników znacznika i skali w milimetrach w obu obrazach	W
WF5	automatyczną segmentację znamienia na zdjęciu we wnętrzu znacznika	W
WF6	segmentację znacznika na obrazie termowizyjnym, niezależną od rejestracji	W
WF7	przeniesienie obszarów (znamię, obrys i otwór znacznika) ze zdjęcia na obraz termowizyjny	W
WF8	pomiar parametrów znamienia: pola, obwodu, średnicy równoważnej, średnic Fereta, kolistości, asymetrii i barwy	W
WF9	wyznaczenie miar zgodności masek znacznika między modalnościami (Dice, IoU, HD95, ASSD, przesunięcie środków, stosunek pól)	W
WF10	ocenę wyników względem adnotacji CVAT, gdy są dostępne	P
WF11	wygenerowanie raportu (HTML, JSON, obrazy PNG) z objaśnieniem wyznaczonych wielkości	W
WF12	zapis każdej analizy i jej wyników w bazie danych	W
WF13	wykonanie wszystkich etapów jednym poleceniem	P
WF14	przetwarzanie wsadowe wielu par oraz raport zbiorczy	P
WF15	zapis, dla każdego piksela obrazu termowizyjnego objętego obszarem znamienia przeniesionym ze zdjęcia, jego współrzędnych (x, y) i surowej intensywności z nagrania kamery	W

Wymagania WF6 i WF9 wynikają bezpośrednio z celu pracy: maska znacznika wyznaczona w obrazie termowizyjnym przez model, który nie uczestniczy w rejestracji, stanowi niezależny punkt odniesienia do oceny zgodności obszaru przeniesionego ze zdjęcia.

3.3 Wymagania pozafunkcjonalne

Wymagania pozafunkcjonalne określają jakość działania systemu. Sformułowano je tak, aby można było je zweryfikować pomiarem lub testem (tab. 3.2).

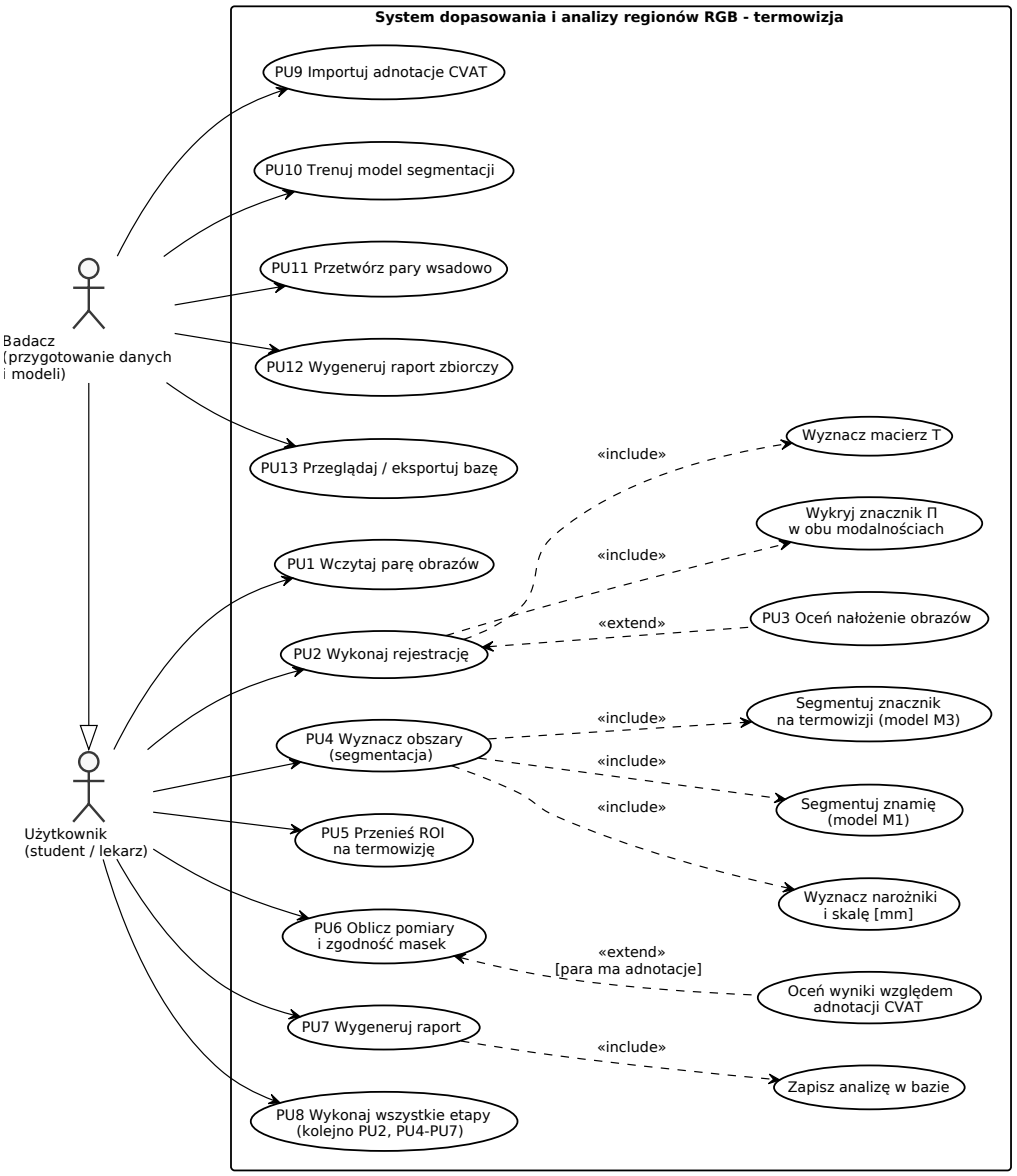
3.4 Przypadki użycia

Funkcjonalność systemu przedstawiono na diagramie przypadków użycia (rys. 3.1). Wyróżniono dwóch aktorów. Użytkownik (student lub lekarz) analizuje pojedyncze pary obrazów i przegląda raporty. Badacz, dziedziczący uprawnienia użytkownika, przygotowuje dane i

Tablica 3.2: Wymagania pozafunkcjonalne systemu

ID	Kategoria	Wymaganie i sposób weryfikacji
WN1	wydajność	rejestracja jednej pary trwa krócej niż 15 s na komputerze klasy PC bez procesora graficznego; weryfikacja: pomiar czasu dla par ze zbioru
WN2	wydajność	segmentacja znacznika na obrazie termowizyjnym trwa krócej niż 1 s bez procesora graficznego
WN3	użyteczność	interfejs pozostaje responsywny podczas obliczeń; postęp i komunikaty są widoczne na bieżąco
WN4	dokładność	mediana błędu TRE na narożnikach znacznika nie przekracza 1 mm
WN5	dokładność	współczynnik Dice'a segmentacji znacznika na obrazie termowizyjnym względem adnotacji wynosi co najmniej 0,9
WN6	niezawodność	niepowodzenie etapu (brak pliku, brak znacznika, pusta maska) skutkuje czytelnym komunikatem, a nie przerwaniem pracy aplikacji; niepewne wykrycie znacznika jest sygnalizowane ostrzeżeniem
WN7	przenośność	aplikacja działa bez biblioteki PyTorch; model segmentacji znamienia jest uruchamiany w osobnym środowisku
WN8	utrzymywalność	etapy przetwarzania są realizowane przez ten sam kod w aplikacji i w przetwarzaniu wsadowym
WN9	powtarzalność	każda analiza jest zapisywana wraz z datą, użytymi modelami, macierzą T i wersją kodu
WN10	ochrona danych	system nie przechowuje danych osobowych; pary obrazów i znamiona są identyfikowane numerami

modele: importuje adnotacje, trenuje modele segmentacji, przetwarza zbiór wsadowo i korzysta z bazy danych.



Rysunek 3.1: Diagram przypadków użycia systemu

Przypadek PU2 obejmuje (relacja «include») wykrycie znacznika w obu modalnościach i wyznaczenie macierzy T, a ocena nałożenia obrazów (PU3) stanowi jego opcjonalne rozszerzenie (relacja «extend»). Ocena wyników względem adnotacji rozszerza przypadek PU6 wyłącznie wtedy, gdy para obrazów ma adnotacje. Scenariusz przypadku PU2 przedstawiono w tabeli 3.3.

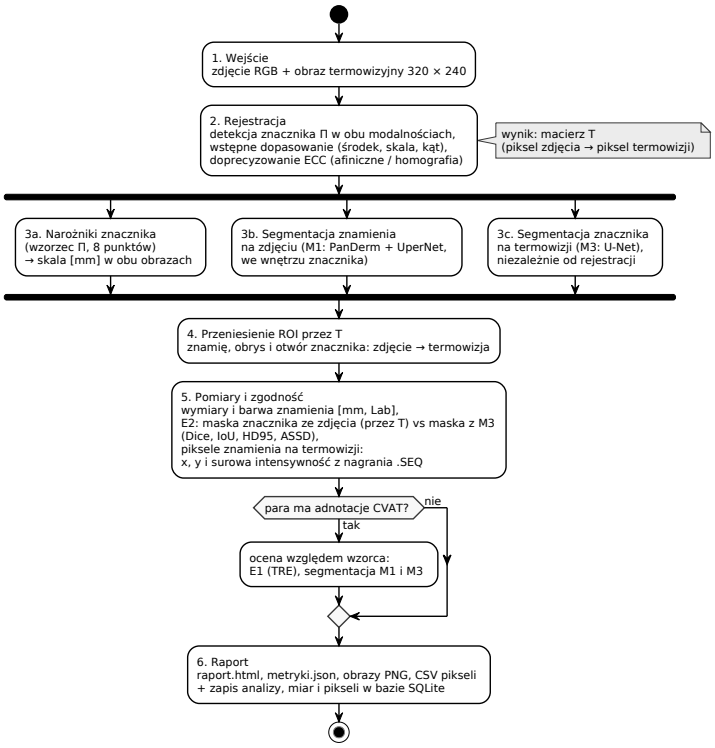
3.5 Architektura systemu

System zaprojektowano w architekturze potokowej, w której każdy etap korzysta z wyników poprzedniego (rys. 3.2). Po wczytaniu pary obrazów system wyznacza macierz rejestracji, następnie – niezależnie od siebie – narożniki znacznika i skalę, maskę znamienia na zdjęciu

Tablica 3.3: Scenariusz przypadku użycia PU2 „Wykonaj rejestrację”

Aktor	Użytkownik
Warunki początkowe	wczytano parę obrazów (PU1)
Scenariusz główny	1. Użytkownik wybiera polecenie rejestracji. 2. System wykrywa znacznik na obrazie termowizyjnym i na zdjęciu. 3. System wyznacza wstępne dopasowanie kształtów znacznika. 4. System doprecyzowuje transformację i wybiera jej model. 5. System wyświetla nałożenie obrazów i zapisuje macierz T.
Scenariusze alternatywne	2a. Znacznik nie zostaje wykryty – system wyświetla komunikat i kończy przypadek. 2b. Kształt wykrytego obiektu słabo odpowiada wzorcowi – system wyświetla ostrzeżenie. 4a. Homografia jest niestabilna – system wybiera przekształcenie afiniczne.
Warunki końcowe	macierz T jest dostępna dla kolejnych etapów

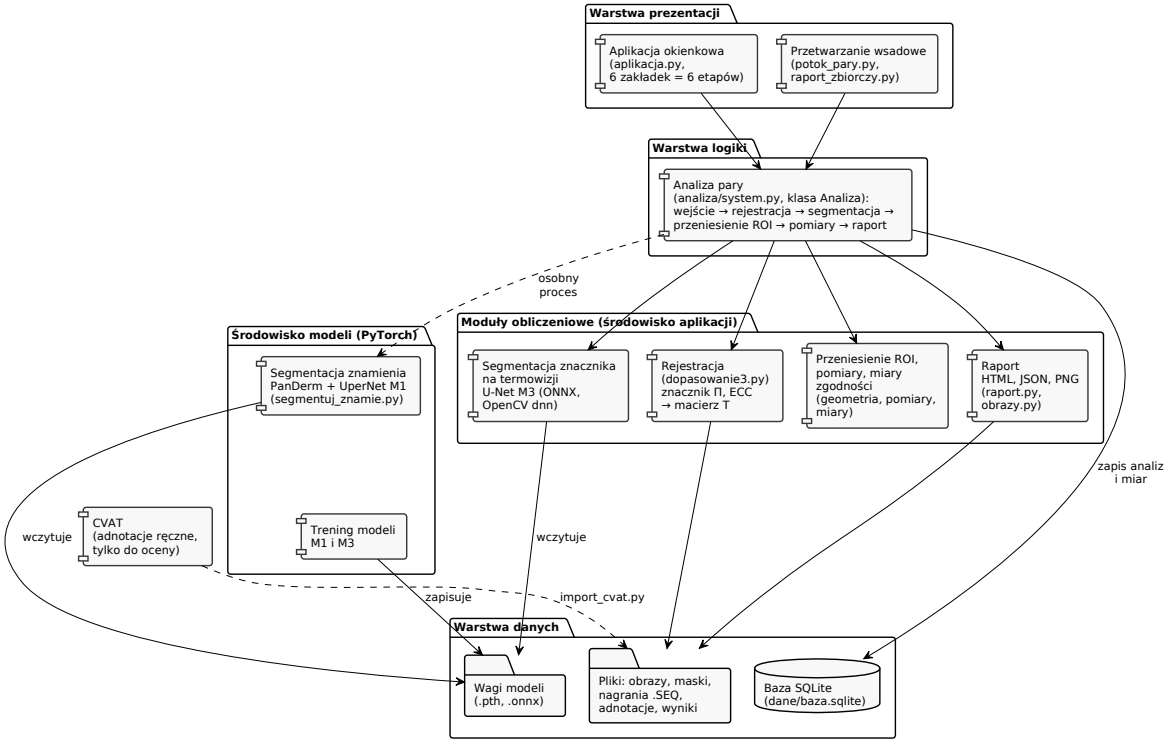
oraz maskę znacznika na obrazie termowizyjnym. Kolejne etapy to przeniesienie obszarów przez macierz T, pomiary i ocena zgodności oraz raport.



Rysunek 3.2: Potok przetwarzania pary obrazów (diagram aktywności UML)

Podział systemu na warstwy przedstawiono na rysunku 3.3. Warstwę prezentacji tworzą aplikacja okienkowa i skrypty przetwarzania wsadowego. Obie korzystają z warstwy logiki, w której etapy potoku realizuje jedna klasa, dzięki czemu ten sam kod jest wykorzystywany zarówno w trybie interaktywnym, jak i wsadowym (WN8). Moduły obliczeniowe odpowiadają za rejestrację, segmentację znacznika na obrazie termowizyjnym, przeniesienie obszarów i pomiary oraz raport. Model segmentacji znamienia działa w osobnym środowisku z biblioteką PyTorch i jest uruchamiany jako odrębny proces, co pozwala zachować lekkie

środowisko aplikacji (WN7). Warstwę danych tworzą pliki obrazów, masek i wyników, wagi modeli oraz baza danych przechowująca wyniki analiz.



Rysunek 3.3: Architektura systemu: warstwy, moduły obliczeniowe i środowiska uruchomieniowe

Rozdział 4

Projekt systemu

W rozdziale opisano decyzje projektowe, które pozwalają spełnić wymagania przedstawione w rozdziale 3: dobór technologii, projekt znacznika referencyjnego, bazy danych, struktury klas oraz interfejsu użytkownika.

4.1 Dobór technologii

Przy wyborze technologii kierowano się dostępnością gotowych implementacji metod opisanych w rozdziale 2, możliwością pracy bez procesora graficznego oraz prostotą instalacji na komputerze użytkownika. Wykorzystane technologie zestawiono w tabeli 4.1.

Rozważano także rejestrację bezpośrednio na intensywnościach obu obrazów z użyciem informacji wzajemnej [23, 16] (metryka `MattesMutualInformation` biblioteki SimpleITK). Podejście to zastosowano we wcześniejszej wersji systemu i zachowano jako metodę porównawczą, natomiast w systemie docelowym transformację wyznacza się na maskach znacznika, zgodnie z wnioskami z przeglądu literatury (podrozdział 2.2.1). Zrezygnowano również z przechowywania wyników w plikach CSV na rzecz bazy danych, która zachowuje historię analiz i relacje między danymi.

4.2 Projekt znacznika referencyjnego

Znacznik referencyjny powinien spełniać następujące wymagania: być widoczny zarówno na zdjęciu, jak i na obrazie termowizyjnym; mieć kształt pozwalający jednoznacznie wyznaczyć położenie, skalę i kąt obrotu; zawierać punkty charakterystyczne umożliwiające wyznaczenie skali w milimetrach i ocenę błędu rejestracji; pozostawiać miejsce na znamię oraz być tani i łatwy do naklejenia.

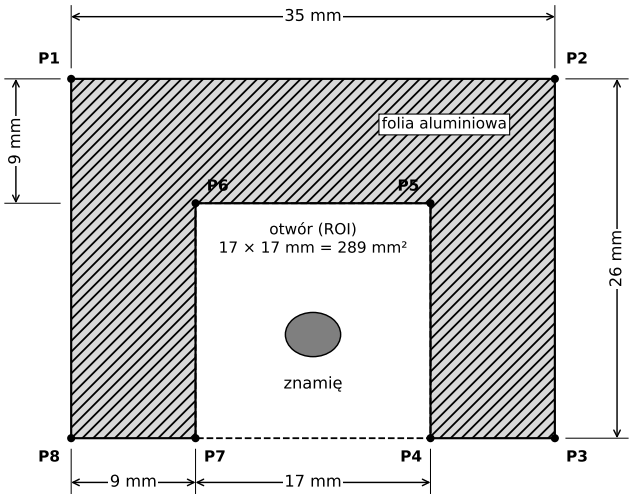
Znacznik wykonano z taśmy pokrytej folią aluminiową. Na zdjęciu folia jest szara, o metalicznym połysku i teksturze załamań, a na obrazie termowizyjnym wyraźnie różni się od skóry, której emisyjność jest bliska jedności [15]. Element aluminiowy (schłodzoną płytę) jako źródło kontrastu w obrazie termowizyjnym wykorzystano także w [6].

Znacznik ma kształt litery Π o wymiarach 35×26 mm i szerokości paska 9 mm (rys. 4.1). Otwór między ramionami ma wymiary 17×17 mm (pole 289 mm^2) i wyznacza obszar zainteresowania, w którym umieszcza się znamię. Osiem narożników znacznika (P1–P8) służy do wyznaczenia homografii przekształcającej piksele na milimetry oraz do oceny błędu rejestracji. Kształt nie ma symetrii obrotowej, dzięki czemu kąt obrotu jest wyznaczany jednoznacznie w pełnym zakresie 360°. Znacznik jest jednak symetryczny

Tablica 4.1: Technologie wykorzystane w systemie

Element	Technologia	Uzasadnienie
język programowania	Python 3.14 (aplikacja)	bogaty ekosystem bibliotek przetwarzania obrazów i uczenia maszynowego; jeden język dla aplikacji i modeli
przetwarzanie obrazów i rejestracja	OpenCV 4.13, NumPy 2.4	gotowa implementacja kryterium ECC [4], operacji morfologicznych i wnioskowania sieci w formacie ONNX
uczenie głębokie	PyTorch 2.11 (osobne środowisko, Python 3.12)	trening sieci U-Net i douczanie modelu PanDerm, którego wagi udostępniono dla tej biblioteki
wnioskowanie sieci U-Net	ONNX + moduł `dnn` biblioteki OpenCV	uruchamianie modelu bez biblioteki PyTorch (WN7)
interfejs graficzny	customtkinter 5.2 (nakładka na tkinter)	lekka biblioteka o otwartej licencji; tkinter jest częścią instalacji Pythona
baza danych	SQLite	baza w jednym pliku, niewymagająca serwera, wystarczająca dla jednego użytkownika
odczyt nagrań termowizyjnych	flirpy 0.3	klatki i surowe wartości detektora z nagrań .SEQ kamery FLIR A320 (WF15)
adnotacje	CVAT	oznaczanie masek i punktów (narożników) w przeglądarce
raport	HTML, JSON, PNG	raport czytelny bez dodatkowego oprogramowania; wyniki w formacie do dalszej analizy
metoda porównawcza	SimpleITK 2.5	rejestracja z informacją wzajemną [23] w badaniu porównawczym

względem osi pionowej, więc odbicie lustrzane obrazu dałoby fałszywe dopasowanie z zamienionymi ramionami; ponieważ żadna z kamer nie odwraca obrazu, przypadku tego nie rozpatruje się.



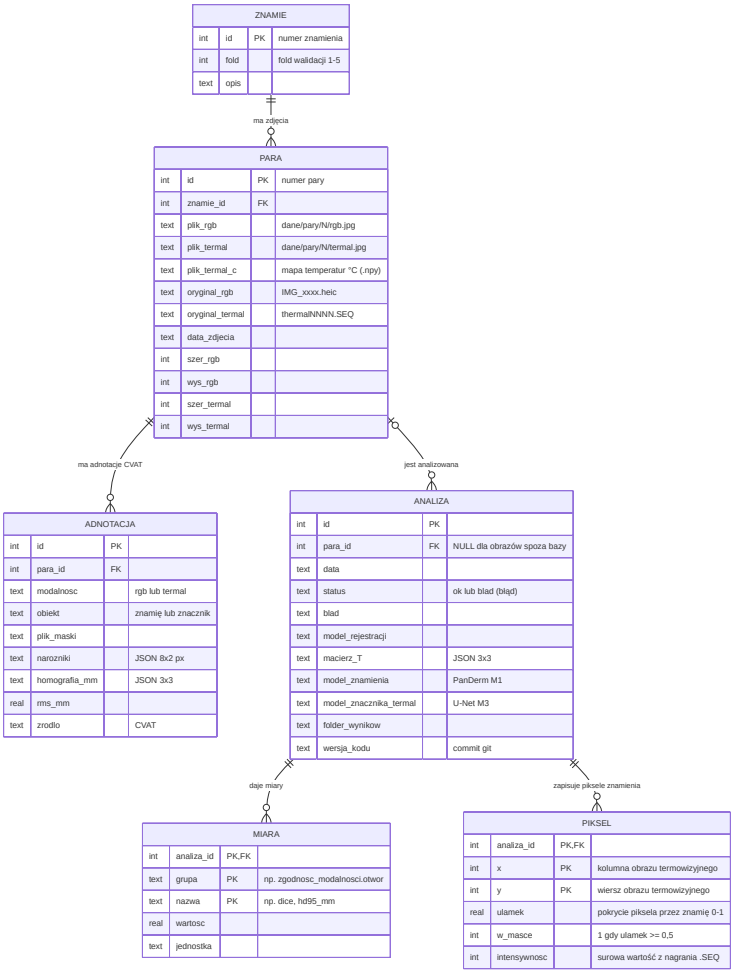
Rysunek 4.1: Wymiary znacznika referencyjnego II; P1–P8 – narożniki wykorzystywane do wyznaczenia skali i błędu rejestracji

We wcześniejszej wersji systemu stosowano znaczniki o dowolnym kształcie, bez wyróżnionych punktów, co uniemożliwiało wyznaczenie skali w milimetrach i niezależną ocenę dokładności rejestracji. Znany kształt znacznika II pozwala natomiast porównywać wykryte maski ze wzorcem i ostrzegać o niepewnej detekcji.

4.3 Projekt bazy danych

Baza danych przechowuje informacje o zbiorze (znamiona, pary obrazów, adnotacje) oraz wyniki wszystkich analiz. Pliki obrazów, masek i raportów pozostają w folderach, a baza zawiera ich ścieżki względne. Rozwiązanie to ogranicza rozmiar bazy i pozwala przeglądać pliki bez dodatkowych narzędzi. Model danych przedstawiono na diagramie związków encji (rys. 4.2), a opis tabel – w tabeli 4.2.

Tabele połączono relacjami jeden do wielu: znamię ma wiele par obrazów, para – wiele adnotacji i analiz, a analiza – wiele miar i wiele pikseli znamienia. Tabelę `miara` zaprojektowano w układzie „długim” (jedna wartość w wierszu), dzięki czemu dodanie nowej miary nie wymaga zmiany schematu bazy. Dodatkowo zdefiniowano dwa widoki: `ostatnia_analiza`, wskazujący najnowszą udaną analizę każdej pary, oraz `wyniki_par`, łączący jej miary z numerem znamienia i foldu. Tabela `piksel` ma klucz główny złożony z identyfikatora analizy i współrzędnych piksela, co wyklucza powtórzenie piksela w jednej analizie i pozwala pobrać piksele znamienia jednym zapytaniem (WF15). Schemat bazy ma numer wersji; przy otwarciu bazy w starszej wersji brakujące tabele są tworzone automatycznie, bez utraty zapisanych analiz. Zapis do bazy następuje automatycznie po wygenerowaniu raportu (WF12, WN9).



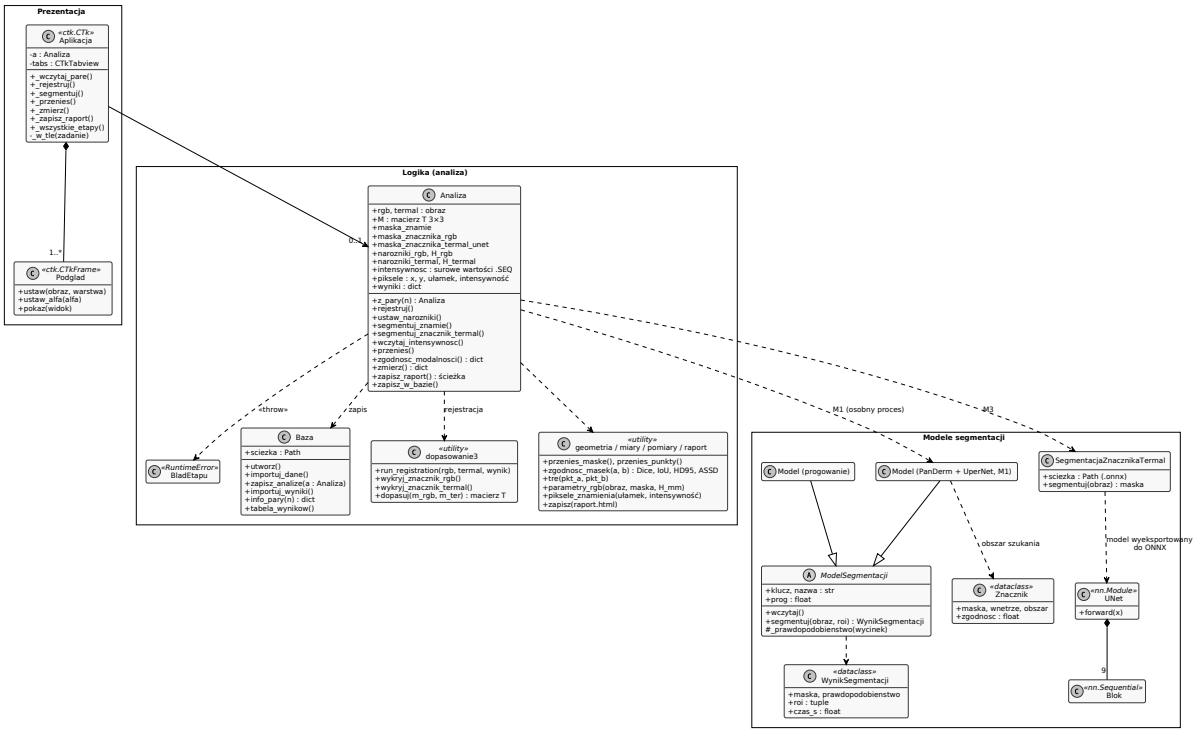
Rysunek 4.2: Diagram związków encji bazy danych systemu

Tablica 4.2: Tabele bazy danych

Tabela	Zawartość
`znamie`	numer znamienia i numer foldu walidacji krzyżowej
`para`	ścieżki zdjęcia i obrazu termowizyjnego, nazwy plików oryginalnych, data wykonania zdjęcia, rozdzielczości; klucz obcy do tabeli `znamie`
`adnotacja`	maski i narożniki znacznika z programu CVAT oraz homografia piksele–milimetry dla danej modalności
`analiza`	każde uruchomienie analizy: data, status, użyte modele, macierz T, folder wyników i wersja kodu
`miara`	wszystkie wyniki liczbowe analizy w postaci: grupa, nazwa, wartość, jednostka
`piksel`	piksele obrazu termowizyjnego objęte znamieniem przeniesionym ze zdjęcia: współrzędne x, y, ułamek pokrycia, przynależność do maski i surowa intensywność z nagrania

4.4 Diagram klas

Strukturę statyczną systemu przedstawiono na diagramie klas (rys. 4.3). Dla czytelności pominięto metody pomocnicze. Centralną klasą systemu jest `Analiza`, która przechowuje stan analizy jednej pary obrazów – obrazy, macierz T, maski, narożniki, surowe wartości detektora, piksele znamienia i wyniki – a jej metody odpowiadają kolejnym etapom potoku przetwarzania. Klasa `Aplikacja` realizuje interfejs graficzny i korzysta z obiektu klasy `Analiza`; podglądy obrazów realizuje klasa `Podglad`. Zapis wyników zapewnia klasa `Baza`, a niepowodzenia etapów są zgłaszane wyjątkiem `BladEtapu`, którego treść jest wyświetlana użytkownikowi (WN6).

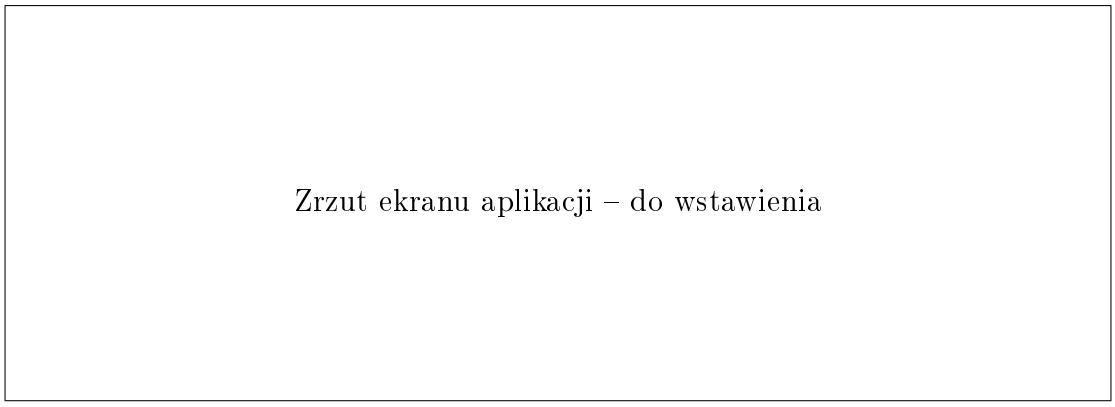


Rysunek 4.3: Diagram klas systemu (z pominięciem metod pomocniczych)

Modele segmentacji zdjęć dziedziczą po klasie abstrakcyjnej `ModelSegmentacji`, która definiuje wspólny interfejs wczytania modelu i segmentacji. Pozwala to dodawać kolejne modele bez zmiany pozostałych części systemu. Segmentację znacznika na obrazie termowizyjnym realizuje klasa `SegmentacjaZnacznikaTermal`, wykorzystująca sieć `UNet` wyeksportowaną do formatu ONNX. Moduły realizujące rejestrację, przekształcenia geometryczne, miary i raport zaimplementowano jako zbiory funkcji, oznaczone na diagramie stereotypem «utility».

4.5 Projekt interfejsu użytkownika

Interfejs zaprojektowano tak, aby odzwierciedlał kolejność etapów przetwarzania. Okno aplikacji składa się z czterech obszarów (rys. 4.4): paska sześciu etapów (Dane, Rejestracja, Segmentacja, Przeniesienie ROI, Pomiary, Raport), panelu sterowania po lewej stronie, podglądów obrazów po prawej oraz paska stanu z dziennikiem zdarzeń w dolnej części okna.



Rysunek 4.4: Okno aplikacji – zakładka rejestracji: 1 – pasek etapów, 2 – panel sterowania, 3 – podgląd nałożenia obrazów, 4 – pasek stanu i dziennik zdarzeń

Każda zakładka kończy się przyciskiem przejścia do kolejnego etapu, a przyciski etapów, których nie można jeszcze wykonać, są nieaktywne, co zapobiega uruchomieniu etapu bez wyników poprzedniego. Podglądy obrazów umożliwiają powiększanie (kółko myszy), przesuwanie (przeciąganie) i powrót do widoku początkowego (dwukrotne kliknięcie), a nałożenie obrazów ma regulowaną przezroczystość (WF3). Obliczenia są wykonywane w osobnym wątku, dzięki czemu interfejs pozostaje responsywny, a postęp jest widoczny na pasku stanu i w dzienniku (WN3). W zakładce pomiarów wybranie nazwy wielkości wyświetla jej objaśnienie, a w zakładce raportu można przejrzeć obrazy raportu, w tym piksele znamienia na obrazie termowizyjnym. Dane można wczytać na dwa sposoby: wybierając numer pary ze zbioru albo dwa dowolne pliki (WF1); dostępne jest też polecenie wykonania wszystkich etapów (WF13). Szczegółowy opis obsługi zawiera instrukcja użytkownika (Dodatek A).

Rozdział 5

Implementacja

W rozdziale opisano implementację modułów systemu: przygotowanie danych, rejestrację, modele segmentacji, przeniesienie obszarów wraz z zapisem pikseli znamienia, pomiary oraz bazę danych, raport i aplikację. System zaimplementowano w języku Python; instalację środowisk i strukturę kodu opisano w dokumentacji technicznej (Dodatek B).

5.1 Akwizycja i przygotowanie danych

Zbiór danych zebrano w jednej serii pomiarowej 23 października 2026 r. Obejmuje on 94 pary obrazów przedstawiających 34 znamiona; każde znamię sfotografowano dwa lub trzy razy, zmieniając obrót znacznika, odległość i kąt wykonania zdjęcia. Zdjęcia wykonano telefonem w formacie HEIC i przekonwertowano do formatu JPG (dłuższy bok 1104–3274 pikseli). Obrazy termowizyjne zarejestrowano kamerą FLIR A320 z obiektywem 18 mm jako nagrania .SEQ o rozdzielczości 320 × 240 pikseli. Z pierwszej klatki każdego nagrania wyznaczono:

- obraz podglądowy z paletą barw, znormalizowany do zakresu między 2. a 98. percentylem wartości nagrania – wykorzystywany w rejestracji i wizualizacji;
- macierz surowych wartości detektora (liczby całkowite 16-bitowe), wykorzystywaną jako intensywność pikseli znamienia (WF15);
- pomocniczo – mapę temperatur obliczoną z parametrów zapisanych w nagraniu przy emisyjności skóry 0,98 [15].

Przy odczycie usuwano dolne wiersze zawierające dane telemetryczne kamery. Zgodność pikseli wszystkich reprezentacji sprawdzono współczynnikiem korelacji rang, który dla każdej z 94 par wyniósł co najmniej 0,95.

Ręczne adnotacje wykonano w programie CVAT: maskę znamienia na zdjęciu, maski znacznika na obu obrazach oraz osiem narożników znacznika w każdej modalności. Z narożników wyznaczono homografię przekształcającą piksele na milimetry w płaszczyźnie znacznika. Adnotacje wykorzystano wyłącznie do oceny wyników oraz do uczenia modelu M3. Na potrzeby walidacji krzyżowej zbiór podzielono na pięć foldów według znamion, a nie zdjęć, aby zdjęcia tego samego znamienia nie trafiały jednocześnie do zbioru uczącego i testowego.

5.2 Moduł rejestracji

Rejestrację zrealizowano zgodnie z założeniem przyjętym w rozdziale 4: transformację wyznacza się na podstawie znacznika Π, a nie całej sceny. Przebieg metody przedstawiono w postaci pseudokodu (algorytm 5.1), a jej wynik dla przykładowej pary – na rysunku 5.1.

5.2.1 Detekcja znacznika

Na obrazie termowizyjnym folia odbija promieniowanie otoczenia, dlatego jest ciemniejsza od skóry albo – przy odbiciach obiektów o różnej temperaturze – silnie teksturowana, podczas gdy skóra jest gładka. Kandydatów na znacznik wyznaczono jako spójne obszary ciemniejsze od skóry (progi 0,5, 0,65 i 0,8 wartości 70. percentyla jasności obrazu) lub o lokalnym odchyleniu standardowym jasności większym niż 6, 10 albo 15, po otwarciu i zamknięciu morfologicznym. Spośród kandydatów wybierano obszar najbardziej podobny do wzorca Π; miarą podobieństwa jest indeks Jaccarda (IoU) kandydata i wzorca o tym samym polu i środku masy, maksymalizowany względem kąta obrotu w zakresie 0–360° z krokiem 4°. Krawędź folii, rozmytą przez optykę kamery, wyznaczono z dokładnością subpikselową, przyjmując w pasie ± 4 pikseli wokół krawędzi próg w połowie między jasnością folii i skóry.

Na zdjęciu folia jest chłodniejsza w barwie od skóry – ma mniejszą sumę składowych a^* i b^* przestrzeni L*a*b* niż mediana skóry – i ma teksturę załamań. Kandydatów wyznaczono przy kilku progach z mapy barwy, mapy tekstury (odchylenie standardowe w oknie 7×7 pikseli) oraz ich połączenia, a wybór przebiega tak samo jak na obrazie termowizyjnym. Krawędź folii doprecyzowano segmentacją interaktywną z biblioteki OpenCV, akceptowaną tylko wtedy, gdy nie pogarsza zgodności kształtu z wzorcem. Detekcję na zdjęciu wykonuje się w skali roboczej, w której dłuższy bok ma 1000 pikseli. Jeżeli zgodność wykrytego obiektu z wzorcem jest mniejsza niż 0,65, system zgłasza ostrzeżenie (WN6).

5.2.2 Dopasowanie wstępne i doprecyzowanie metodą ECC

Dopasowanie wstępne jest przekształceniem przez podobieństwo: przesunięcie wynika ze środków mas masek znacznika, skala – z pierwiastka stosunku ich pól, a kąt – z maksimum IoU masek po obrocie (krok 2°, a następnie $\pm 2°$ z krokiem 0,25°). Transformację doprecyzowano, maksymalizując kryterium ECC [4] funkcją `findTransformECC` biblioteki OpenCV. Kryterium obliczano nie na intensywnościach obrazów, lecz na maskach znacznika rozmytych filtrem Gaussa, co sprowadza problem wielomodalny do jednomodalnego (podrozdział 2.2.1). Optymalizację prowadzono od dużego do małego rozmycia: dla przekształcenia afinicznego przy $\sigma = 6$, 3 i 1,5 piksela, a następnie dla homografii przy $\sigma = 3$ i 1,5 piksela (do 200 iteracji, $\varepsilon = 10^{-6}$), na wycinku obejmującym znacznik z marginesem 30%. Rozmycie poszerza obszar zbieżności metody gradientowej, a jego stopniowe zmniejszanie zwiększa dokładność.

5.2.3 Wybór modelu przekształcenia

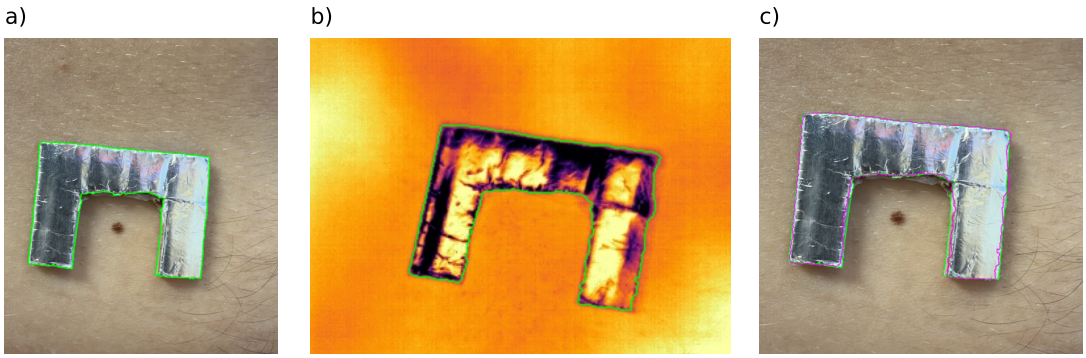
Domyślnie przyjmowano przekształcenie afiniczne. Homografię wybierano wtedy, gdy zmniejszała średni błąd krawędzi masek o ponad 5% i była stabilna, tzn. lokalna skala pola w narożnikach kadru zdjęcia różniła się od skali w środku znacznika najwyżej dwukrotnie. Warunek ten odrzuca homografie dopasowane do znacznika, ale zniekształcające pozostałą

część obrazu. W zbiorze 92 przeanalizowanych par homografię wybrano 65 razy, a przekształcenie afiniczne – 27 razy. Wynikiem modułu jest macierz T przekształcająca piksel zdjęcia na piksel obrazu termowizyjnego, obraz termowizyjny w geometrii zdjęcia (z kanałem przezroczystości wyznaczającym pole widzenia kamery) oraz nałożenie obu obrazów.

Algorytm 5.1 Rejestracja zdjęcia i obrazu termowizyjnego na podstawie znacznika Π

Wejście: zdjęcie I_R, obraz termowizyjny I_T, wzorzec Π
Wyjście: macierz T (piksel $I_R \to$ piksel I_T), model przekształcenia

$M_T \leftarrow$ WykryjZnacznik(I_T) ▷ obszary ciemne lub teksturowane
$M_R \leftarrow$ WykryjZnacznik(I_R) ▷ obszary chłodne w barwie lub teksturowane
jeżeli $\mathrm{IoU}(M_R, \Pi) < 0{,}65$ **lub** $\mathrm{IoU}(M_T, \Pi) < 0{,}65$ **to**
    zgłoś ostrzeżenie o niepewnej detekcji znacznika
$W_0 \leftarrow$ podobieństwo: środki mas, skala $\sqrt{|M_T|/|M_R|}$, kąt $\arg\max_\alpha \mathrm{IoU}\big(\mathrm{obrt}_\alpha(M_R), M_T\big)$
$W_A \leftarrow W_0$
dla $\sigma \in (6;\ 3;\ 1{,}5)$ **wykonaj**
    $W_A \leftarrow \mathrm{ECC}_{\text{afiniczne}}(G_\sigma * M_R,\ G_\sigma * M_T,\ W_A)$
$W_H \leftarrow W_A$
dla $\sigma \in (3;\ 1{,}5)$ **wykonaj**
    $W_H \leftarrow \mathrm{ECC}_{\text{homografia}}(G_\sigma * M_R,\ G_\sigma * M_T,\ W_H)$
jeżeli $e(W_H) < 0{,}95\, e(W_A)$ **oraz** W_H stabilna **to** ▷ e – średni błąd krawędzi masek
    zwróć W_H, homografia
w przeciwnym razie
    zwróć W_A, przekształcenie afiniczne



Rysunek 5.1: Rejestracja pary 14: a) folia wykryta na zdjęciu, b) folia wykryta na obrazie termowizyjnym, c) kontur folii ze zdjęcia (zielony) i kontur folii z obrazu termowizyjnego przeniesiony przekształceniem odwrotnym do T (fioletowy). Źródło: opracowanie własne

5.3 Modele segmentacji

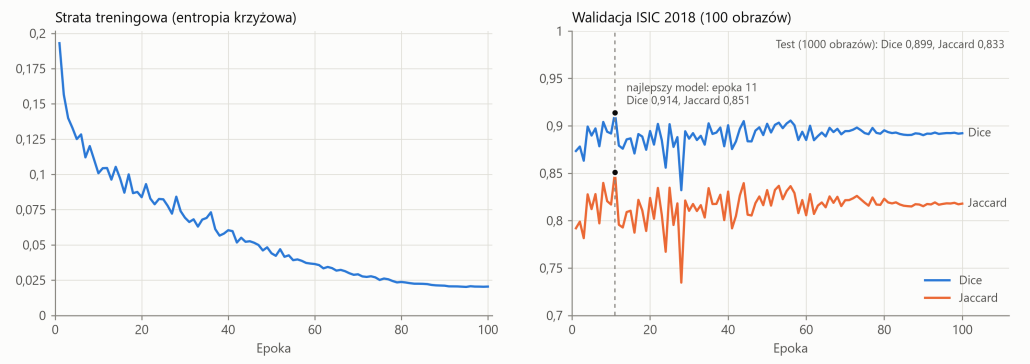
Zgodnie z celem pracy każda modalność ma własny model segmentacji. Na zdjęciu segmentowane jest znamię (model M1), a na obrazie termowizyjnym – znacznik (model M3), ponieważ znamię nie jest na nim widoczne. Parametry uczenia obu modeli zestawiono w tabeli 5.1.

Tablica 5.1: Parametry uczenia modeli segmentacji

Parametr	M1: PanDerm + UperNet	M3: U-Net
zadanie	znamię na zdjęciu	znacznik na obrazie termowizyjnym
dane uczące	ISIC 2018 Task 1: 2594 / 100 / 1000 obrazów	94 obrazy własne, 5 foldów według znamion
wejście	224 × 224, RGB	240 × 320, skala szarości
architektura	koder ViT-L z wagami PanDerm, dekoder UperNet	U-Net, kanały 16–256, 1,94 mln parametrów
funkcja straty	entropia krzyżowa	BCE + (1 − miękki Dice)
optymalizator	AdamW (8-bitowy), $\eta = 10^{-4}$, $\lambda = 0{,}05$	AdamW, $\eta = 2 \cdot 10^{-3}$, $\lambda = 10^{-4}$
harmonogram	kosinusowy, 100 epok, wybór epoki na zbiorze walidacyjnym	kosinusowy, 60 epok, bez wyboru epoki
paczka	2	8
augmentacja	zmiany barw, skala szarości, autokontrast, negatyw	obrót 0–360°, skala 0,75–1,3, przesunięcie, odbicia, korekcja gamma, kontrast, rozmycie, szum
uruchamianie	PyTorch, osobny proces	ONNX + OpenCV w aplikacji

5.3.1 Model M1 – znamię na zdjęciu

Model M1 składa się z kodera PanDerm (transformer wizyjny ViT-L) z wagami udostępnionymi przez autorów [21] oraz dekodera UperNet [20]. Model douczono na zbiorze ISIC 2018 Task 1 [3] według procedury autorów modelu PanDerm; ze względu na kartę graficzną o pamięci 8 GB zastosowano 8-bitową wersję optymalizatora AdamW i obliczenia w formacie bfloat16. Model wybrano po 11. epoce, w której indeks Jaccarda na zbiorze walidacyjnym był największy (rys. 5.2). Na zbiorze testowym (1000 obrazów) uzyskano współczynnik Dice'a 0,899 i indeks Jaccarda 0,833.



Rysunek 5.2: Douczanie modelu M1 na zbiorze ISIC 2018: strata na zbiorze uczącym (po lewej) oraz współczynnik Dice'a i indeks Jaccarda na zbiorze walidacyjnym (po prawej). Źródło: opracowanie własne

Bezpośrednie zastosowanie modelu do zdjęć z telefonu dawało maski znacznie zawyżone. Przyczyną jest przesunięcie dziedziny: w obrazach dermatoskopowych ISIC znamię zajmuje około połowy kadru, a na zdjęciu ze znacznikiem znamię o średnicy 1–4 mm zajmuje niewielką część otworu o boku 17 mm. Dlatego obszar segmentacji ograniczono do otworu znacznika poszerzonego o 8% (piksele folii zastępuje się medianą barwy skóry), a segmentację

podzielono na dwa kroki. Najpierw wyznacza się do trzech kandydatów na znamię jako plamy ciemniejsze od lokalnego tła skóry: jasność po domknięciu morfologicznym o promieniu ok. 0,2 mm, usuwającym włosy, porównuje się z medianą w oknie 8 mm, odrzucając pasy wzdłuż folii i kształty wydłużone. Następnie model segmentuje kadr wokół każdego kandydata, dobrany tak jak w danych uczących ISIC (znamię zajmuje ok. 53% dłuższego boku kadru), a spośród wyników wybiera się maskę o największym kontraście brzegu, czyli różnicy jasności wewnątrz maski i w pasie 0,4 mm na zewnątrz niej. Model M1 działa w osobnym środowisku z biblioteką PyTorch i jest uruchamiany przez aplikację jako odrębny proces (WN7).

5.3.2 Model M3 – znacznik na obrazie termowizyjnym

Model M3 jest siecią U-Net [17] zmniejszoną do rozmiaru zbioru: koder i dekoder mają cztery poziomy o liczbie kanałów 16, 32, 64 i 128, a najgłębsza warstwa – 256 kanałów. Każdy z dziewięciu bloków składa się z dwóch splotów 3×3 z normalizacją wsadową i funkcją aktywacji ReLU; sieć ma 1,94 mln parametrów. Wejściem jest obraz termowizyjny w skali szarości, standaryzowany osobno dla każdego obrazu, a wyjściem – mapa prawdopodobieństwa przynależności piksela do folii, progowana wartością 0,5. Sieć uczono na 94 maskach znacznika z programu CVAT w 5-krotnej walidacji krzyżowej według znamion; dla każdej pary system używa modelu foldu, w którym była ona w zbiorze testowym, a dla obrazów spoza zbioru – modelu uczonego na wszystkich parach. Liczbę epok ustalono z góry, bez wyboru epoki na zbiorze testowym, aby nie zawyżać wyników, a niewielki rozmiar zbioru kompensowano silną augmentacją. Wytrenowane sieci wyeksportowano do formatu ONNX i uruchamia się je modułem `dnn` biblioteki OpenCV, bez biblioteki PyTorch; segmentacja jednego obrazu trwa ok. 67 ms na procesorze (WN2). Model M3 nie uczestniczy w rejestracji, dlatego jego maska stanowi niezależny punkt odniesienia w badaniu E2.

5.4 Przeniesienie obszarów i skala metryczna

Skalę metryczną wyznaczono z narożników znacznika. Wzorzec Π o znanych wymiarach dopasowano do maski znacznika w każdej modalności (podobieństwo, a następnie ECC dla przekształcenia afinicznego i homografii), a osiem wierzchołków dopasowanego wzorca przyjęto za narożniki. Z narożników wyznaczono homografię H przekształcającą piksele obrazu na milimetry w płaszczyźnie znacznika. Lokalny rozmiar piksela w danym punkcie jest pierwiastkiem z wartości bezwzględnej wyznacznika jakobianu H; dla obrazu termowizyjnego wynosi on 0,21–0,44 mm (mediana 0,28 mm).

Obszary przenoszono wektorowo (algorytm 5.2). Kontur maski znamienia na zdjęciu, poszerzony o pół piksela (kontur prowadzony przez środki pikseli brzegowych zaniżałby pole), przekształcano macierzą T, a powstały wielokąt wypełniano w siatce czterokrotnie gęstszej niż piksele obrazu termowizyjnego. Średnia w bloku 4×4 daje ułamek pokrycia każdego piksela przez znamię (wielokrotność 1/16). Pozwala to zachować kształt małego obszaru – znamię obejmuje na obrazie termowizyjnym od 10 do 290 pikseli – przy błędzie pola rzędu 1%. W ten sam sposób przenoszono obrys i otwór znacznika.

Dla każdego piksela obrazu termowizyjnego o niezerowym ułamku pokrycia system zapisuje jego współrzędne x (kolumna) i y (wiersz), ułamek pokrycia oraz surową intensywność odczytaną z nagrania .SEQ (WF15). Piksel uznaje się za należący do znamienia, gdy znamię pokrywa co najmniej połowę jego pola, co odpowiada przeniesieniu maski binarnej.

Pozostałe piksele są zapisywane wraz z ułamkiem pokrycia, co umożliwia analizę z wagami. Lista pikseli trafia do pliku CSV i do tabeli `piksel` bazy danych.

Algorytm 5.2 Przeniesienie znamienia na obraz termowizyjny i zapis pikseli

Wejście: maska znamienia Z na zdjęciu, macierz T, surowe wartości detektora I (320×240)
Wyjście: lista pikseli $(x, y, u, m, I(x,y))$

$K \leftarrow$ kontur maski Z poszerzony o pół piksela
$K' \leftarrow T \cdot K$ ▷ wierzchołki we współrzędnych obrazu termowizyjnego
$G \leftarrow$ wypełnienie wielokąta K' w siatce 1280×960 ▷ 4 razy gęstszej
dla wszystkich piksele (x, y) obrazu termowizyjnego **wykonaj**
    $u \leftarrow$ średnia G w bloku 4×4 odpowiadającym pikselowi (x, y)
    jeżeli $u > 0$ **to**
        $m \leftarrow [\, u \geq 0{,}5 \,]$ ▷ piksel w masce znamienia
        dopisz $(x, y, u, m, I(x,y))$ do listy
zapisz listę do pliku CSV i tabeli `piksel`

5.5 Pomiary i miary zgodności

Parametry znamienia oblicza się na zdjęciu, przeliczając kontur maski na milimetry homografią H. Wyznaczane są: pole P, obwód L, średnica równoważna $d = 2\sqrt{P/\pi}$, maksymalna i minimalna średnica Fereta (z otoczki wypukłej i najmniejszego prostokąta opisanego), kolistość $4\pi P/L^2$, asymetria względem osi głównej i osi prostopadłej – jako część pola niepokryta po odbiciu kształtu względem danej osi – oraz średnia barwa w przestrzeni L*a*b* (WF8).

Miary zgodności dwóch masek A i B (podrozdział 2.4) oblicza się w siatce czterokrotnie gęstszej niż piksele obrazu termowizyjnego, aby schodkowy brzeg pikseli nie zaniżał wyniku. Są to: współczynnik Dice'a, indeks Jaccarda (IoU), stosunek pól $|A|/|B|$, przesunięcie środków ciężkości oraz HD95 i ASSD obliczane z transformaty odległości brzegów masek; odległości przelicza się na milimetry lokalnym rozmiarem piksela. Błąd TRE [5] jest średnią odległością ośmiu narożników znacznika oznaczonych na zdjęciu i przeniesionych macierzą T od narożników oznaczonych na obrazie termowizyjnym, mierzoną w milimetrach w płaszczyźnie znacznika:

$$\mathrm{TRE} = \frac{1}{8} \sum_{i=1}^{8} \left\| H_T\big(T\, p_i^R\big) - H_T\big(p_i^T\big) \right\|, \tag{5.1}$$

gdzie p_i^R i p_i^T to i-ty narożnik na zdjęciu i na obrazie termowizyjnym, a H_T – homografia obrazu termowizyjnego (piksele $\rightarrow$ mm).

W badaniu E2 maską A jest folia znacznika wykryta na zdjęciu przez detektor modułu rejestracji i przeniesiona macierzą T, a maską B – folia wyznaczona na obrazie termowizyjnym przez model M3. Otwór znacznika, czyli obszar zainteresowania, wyznacza się dla obu masek tą samą funkcją – jako otoczkę wypukłą maski pomniejszoną o folię.

5.6 Baza danych, raport i aplikacja

Bazę danych zaimplementowano z użyciem modułu `sqlite3` biblioteki standardowej języka Python. Schemat jest zdefiniowany w kodzie i ma numer wersji; baza tworzy się automatycznie

przy pierwszym zapisie analizy, a przy otwarciu bazy w starszej wersji dopisywane są brakujące tabele. Po każdej analizie zapisywany jest wiersz w tabeli `analiza`, wszystkie wartości liczbowe wyników w tabeli `miara` oraz piksele znamienia w tabeli `piksel`; nieudana analiza jest zapisywana ze statusem błędu i jego opisem. Obsługę bazy z wiersza poleceń – import danych, podsumowanie, eksport wyników i pikseli do plików CSV oraz dowolne zapytania SQL – zapewnia skrypt `baza_danych.bat`.

Raport pary jest pojedynczym plikiem HTML z osadzonymi obrazami, który można otworzyć w dowolnej przeglądarce. Zawiera opis wykonanych etapów, obrazy (znacznik i narożniki, nałożenie, powiększenie wokół znamienia, maski badania E2, piksele znamienia), tabele wyników i objaśnienie każdej wielkości. System dodaje uwagi, gdy wynik wymaga sprawdzenia, np. gdy błąd TRE przekracza 1 mm, współczynnik Dice'a w badaniu E2 jest mniejszy niż 0,85, zgodność znacznika z wzorcem jest mniejsza niż 0,65 lub brakuje nagrania .SEQ. Obok raportu zapisywane są plik `metryki.json` z wynikami liczbowymi, obrazy PNG i plik CSV z pikselami znamienia.

Aplikację okienkową zaimplementowano z użyciem biblioteki customtkinter. Etapy potoku są wywoływane metodami klasy `Analiza` w osobnym wątku roboczym, a komunikaty i wyniki trafiają do interfejsu przez kolejkę, dzięki czemu okno pozostaje responsywne (WN3); wyjątki etapów są przechwytywane i wyświetlane w oknie dialogowym (WN6). Te same metody wykorzystuje skrypt przetwarzania wsadowego `potok_pary.py`; w trybie `-z_zapisanych` korzysta on z zapisanej rejestracji i masek modelu M1, co pozwala przeliczyć pomiary bez procesora graficznego (WF14, WN8). Skrypt `raport_zbiorczy.py` zestawia wyniki wszystkich par i generuje tabele wykorzystane w rozdziale 6.

Rozdział 6

Testy i wyniki

W rozdziale przedstawiono protokół oceny, wyniki badania dokładności rejestracji (E1) i porównania metod rejestracji (E4), ocenę jakości segmentacji w obu modalnościach, zgodność obszarów między modalnościami bez adnotacji (badanie E2), parametry znamion i pikseli na obrazie termowizyjnym oraz wyniki testów funkcjonalnych. Rozdział zamyka dyskusja ograniczeń.

6.1 Zbiór danych i protokół oceny

Badania przeprowadzono na zbiorze 94 par obrazów 34 znamion (podrozdział 5.1). System przeanalizował 92 pary. W parach 75 i 76 kształt obiektu wykrytego na zdjęciu był niezgodny z wzorcem Π (zgodność 0,54 i 0,58 przy progu 0,65), dlatego zgodnie z wymaganiem WN6 analiza zakończyła się komunikatem, a nie błędnym wynikiem. Wzorcem do oceny były adnotacje z programu CVAT, których system nie wykorzystuje w trakcie analizy. Przed wykonaniem badań przyjęto kryteria akceptacji z rozdziału 3: czas rejestracji krótszy niż 15 s (WN1), mediana błędu TRE nie większa niż 1 mm (WN4) i współczynnik Dice'a segmentacji znacznika na obrazie termowizyjnym co najmniej 0,9 (WN5).

Ze względu na skośne rozkłady błędów podano medianę i zakres wartości, a obok nich średnią i odchylenie standardowe. Wyniki dwóch metod uzyskane na tych samych parach porównywano testem Wilcoxona dla par wiązanych, a zależność dwóch miar oceniano współczynnikiem korelacji rang Spearmana ρ.

6.2 Dokładność rejestracji

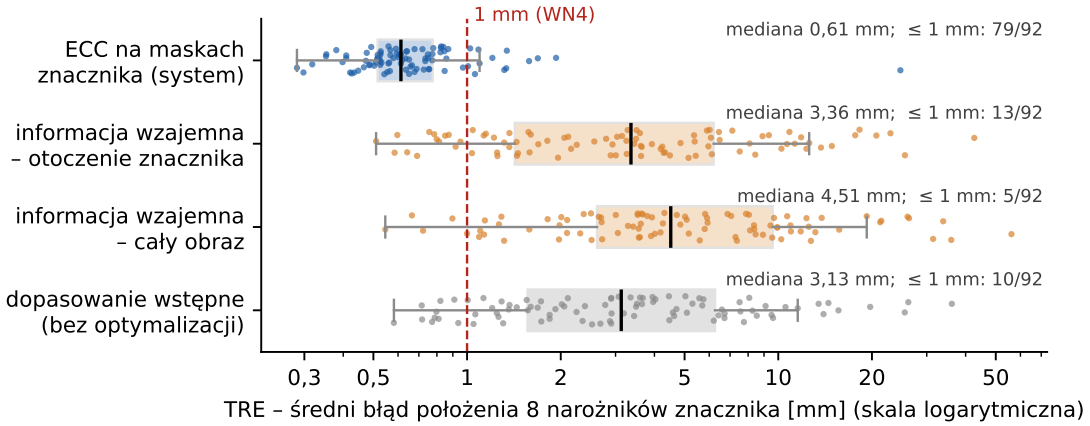
W badaniu E1 narożniki i obrys znacznika oznaczone na zdjęciu przeniesiono macierzą T wyznaczoną przez system i porównano z oznaczonymi na obrazie termowizyjnym (tab. 6.1, kolumna E1). Mediana błędu TRE wyniosła 0,61 mm, a w 78 z 92 par (85%) średni błąd narożników nie przekroczył 1 mm – wymaganie WN4 zostało spełnione. Średnia (0,96 ± 2,52 mm) jest zawyżona przez jedną parę: w parze 78 rejestracja nie powiodła się (TRE 24,7 mm). Kolejne największe błędy wystąpiły w parach 8 (2,3 mm), 79 (1,9 mm) i 72 (1,7 mm). Rozmiar piksela obrazu termowizyjnego na skórze wynosił 0,21–0,44 mm (mediana 0,28 mm), typowy błąd rejestracji odpowiada więc około dwóm pikselom kamery termowizyjnej.

W badaniu E4 porównano metodę zastosowaną w systemie z rejestracją opartą na informacji wzajemnej [23] (metryka `MattesMutualInformation` biblioteki SimpleITK,

Tablica 6.1: Zgodność znacznika po rejestracji: E1 – obrys i narożniki z CVAT na zdjęciu przeniesione macierzą T względem oznaczonych na obrazie termowizyjnym; E2 – maska folii ze zdjęcia przeniesiona macierzą T względem maski z modelu M3, bez adnotacji; mediana (min.–maks.), $n = 92$

Miara	E1 (wzorzec CVAT)	E2 (model M3)
TRE – średni błąd narożników [mm]	0,61 (0,29–24,69)	–
TRE – największy błąd narożnika [mm]	1,13 (0,44–43,85)	–
Dice znacznika	0,960 (0,548–0,979)	0,966 (0,719–0,980)
IoU znacznika	0,923 (0,377–0,959)	0,934 (0,562–0,960)
HD95 znacznika [mm]	0,81 (0,28–19,57)	0,75 (0,42–8,97)
ASSD znacznika [mm]	0,32 (0,16–5,63)	0,25 (0,14–2,17)
Dice otworu (ROI)	0,960 (0,545–0,983)	0,960 (0,597–0,980)
HD95 otworu [mm]	0,75 (0,30–11,55)	0,88 (0,44–6,59)

stosowana we wcześniejszej wersji systemu) w dwóch wariantach: na całym obrazie i w otoczeniu znacznika. Wszystkie metody startowały z tego samego dopasowania wstępnego, a ich dokładność oceniano błędem TRE (rys. 6.1). Rejestracja na maskach znacznika osiągnęła medianę TRE 0,61 mm (rozstęp międzykwartylowy 0,52–0,78 mm) i błąd nie większy niż 1 mm w 79 z 92 par. Informacja wzajemna w otoczeniu znacznika dała medianę 3,36 mm (13 par z błędem do 1 mm), a na całym obrazie – 4,51 mm (5 par). Metoda zastosowana w systemie dała mniejszy błąd niż lepszy z wariantów informacji wzajemnej w 87 z 92 par (test Wilcoxona, $p < 0{,}001$). Informacja wzajemna nie poprawiła nawet dopasowania wstępnego (mediana 3,13 mm), co jest zgodne z obserwacją, że intensywności obrazu widzialnego i termowizyjnego nie są ze sobą bezpośrednio powiązane [7], a funkcja informacji wzajemnej może mieć wiele maksimów [16].



Rysunek 6.1: Błąd TRE czterech metod rejestracji w badaniu E4 ($n = 92$ pary); punkty – pary, prostokąt – kwartyle, czarna linia – mediana. Źródło: opracowanie własne

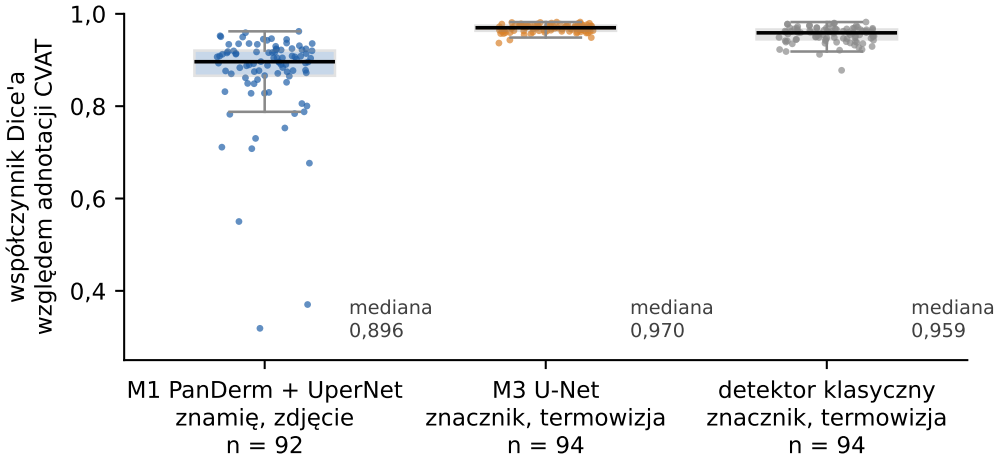
Mediana czasu rejestracji metodą zastosowaną w systemie wyniosła 8,4 s (maksymalnie 13,2 s), wobec 10,5 s i 16,0 s dla wariantów informacji wzajemnej; wymaganie WN1 zostało spełnione.

6.3 Jakość segmentacji w obu modalnościach

Jakość segmentacji oceniono względem masek z programu CVAT (tab. 6.2, rys. 6.2). Model M3 w 5-krotnej walidacji krzyżowej według znamion uzyskał współczynnik Dice'a 0,969 ± 0,008 (minimum 0,937), a wartości w poszczególnych foldach mieściły się w zakresie 0,968–0,970. Współczynnik Dice'a był nie mniejszy niż 0,9 dla wszystkich 94 obrazów, więc wymaganie WN5 zostało spełnione. Model zachowuje pole znacznika (stosunek pól 1,004), a mediana HD95 wynosi 0,62 mm, czyli około dwa piksele obrazu termowizyjnego. Detektor klasyczny z modułu rejestracji uzyskał mniejszy współczynnik Dice'a (0,954 ± 0,017; test Wilcoxona, $p < 0{,}001$) i zaniżał pole folii (stosunek pól 0,950), co uzasadnia zastosowanie modelu uczonego jako niezależnego punktu odniesienia w badaniu E2.

Tablica 6.2: Segmentacja względem adnotacji z CVAT: średnia ± odchylenie standardowe (mediana)

Miara	M1 – znamię, zdjęcie ($n = 92$)	M3 – znacznik, termowizja ($n = 94$)	detektor klasyczny, termowizja ($n = 94$)
Dice	0,870 ± 0,103 (0,896)	0,969 ± 0,008 (0,970)	0,954 ± 0,017 (0,959)
IoU	0,782 ± 0,129 (0,812)	0,939 ± 0,015 (0,941)	0,913 ± 0,031 (0,921)
HD95 [mm]	0,38 ± 0,53 (0,24)	0,68 ± 0,27 (0,62)	1,06 ± 0,59 (0,83)
ASSD [mm]	0,15 ± 0,22 (0,10)	0,23 ± 0,06 (0,22)	0,32 ± 0,12 (0,31)
stosunek pól	1,22 ± 0,59 (1,10)	1,004 ± 0,030 (1,006)	0,950 ± 0,044 (0,951)



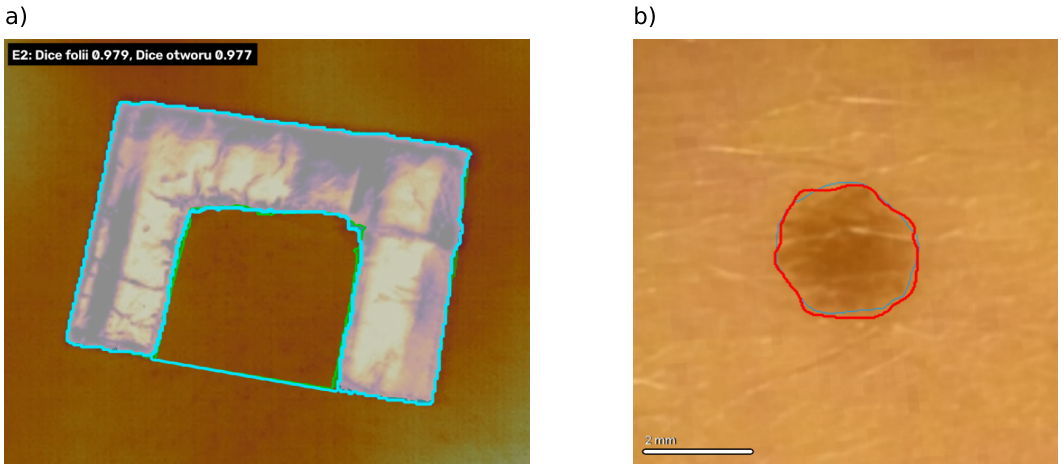
Rysunek 6.2: Współczynnik Dice'a segmentacji względem adnotacji z CVAT; punkty – pary obrazów. Źródło: opracowanie własne

Model M1 na zdjęciach z telefonu uzyskał współczynnik Dice'a 0,870 ± 0,103 (mediana 0,896), a więc niewiele mniejszy niż na zbiorze testowym ISIC (0,899), mimo przesunięcia dziedziny. W 81 z 92 par współczynnik był nie mniejszy niż 0,8. Najsłabsze wyniki dotyczyły znamion położonych przy krawędzi folii lub w jej cieniu (pary 57 i 81: 0,32 i 0,37) oraz bardzo bladego znamienia (para 59: 0,55). Mediana stosunku pól równa 1,10 oznacza, że model systematycznie zawyża obszar znamienia, głównie przez szerszy niż w adnotacji brzeg. Znamiona są małe (mediana średnicy 2,1 mm), a dla małych

struktur miary pokrycia są bardzo wrażliwe na błąd pojedynczych pikseli [11]; dlatego obok współczynnika Dice'a podano miary odległościowe, z których wynika, że typowe przesunięcie brzegu maski (mediana ASSD) wynosi 0,10 mm.

6.4 Zgodność obszaru zainteresowania między modalnościami

Badanie E2 nie wymaga adnotacji, dlatego system wykonuje je dla każdej analizowanej pary. Maska folii ze zdjęcia, przeniesiona macierzą T, pokrywała się z maską z modelu M3 ze współczynnikiem Dice'a 0,957 $\pm$ 0,032 (mediana 0,966), a w 89 z 92 par współczynnik był nie mniejszy niż 0,9 (tab. 6.1, kolumna E2). Dla otworu znacznika, czyli obszaru zainteresowania, mediana współczynnika Dice'a wyniosła 0,960, mediana HD95 – 0,88 mm, a mediana przesunięcia środków – 0,23 mm. Przykład dla pary 14 przedstawiono na rysunku 6.3.

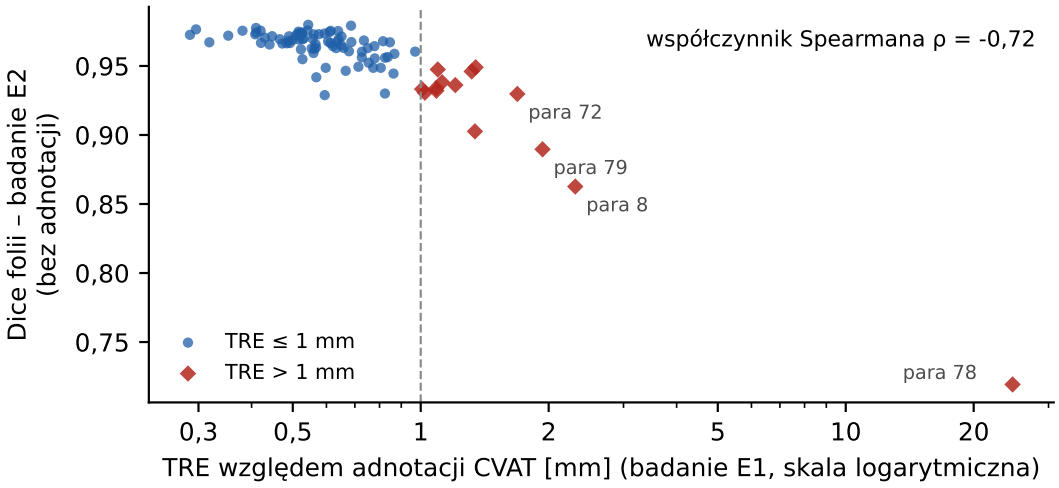


Rysunek 6.3: Para 14: a) maska folii ze zdjęcia przeniesiona macierzą T i maska z modelu M3 (biały – obie maski, zielony – tylko ze zdjęcia, turkusowy – tylko M3), b) nałożenie obrazu termowizyjnego na zdjęcie w otoczeniu znamienia: maska M1 (czerwona) i adnotacja z CVAT (niebieska); widoczne kwadraty to piksele kamery termowizyjnej. Źródło: opracowanie własne

Najważniejszą właściwością badania E2 jest to, że wykrywa ono nieudaną rejestrację bez wzorca. Współczynnik Dice'a folii w badaniu E2 jest silnie skorelowany z błędem TRE wyznaczonym względem adnotacji ($\rho = -0{,}72$; rys. 6.4). Najmniejsze wartości wystąpiły w parach o największym błędzie rejestracji: 78 (Dice 0,72, TRE 24,7 mm), 8 (0,86; 2,3 mm) i 79 (0,89; 1,9 mm). Współczynnik Dice'a otworu mniejszy niż 0,93 wystąpił w 10 parach, z których 9 miało TRE większe niż 1 mm. Badanie E2 ujawnia również błędy segmentacji w jednej z modalności: w parze 1 maska folii ze zdjęcia wchodziła w otwór znacznika, co obniżyło współczynnik Dice'a otworu do 0,81 przy poprawnej rejestracji.

6.5 Parametry znamion i piksele na obrazie termowizyjnym

Parametry znamion zmierzone przez system oraz charakterystykę pikseli znamion na obrazie termowizyjnym zestawiono w tabeli 6.3. Znamiona w zbiorze były małe: mediana pola wyniosła 3,4 mm^2, a średnicy równoważnej – 2,1 mm. Stosunek pola znamienia



Rysunek 6.4: Współczynnik Dice'a folii w badaniu E2 (bez adnotacji) a błąd TRE względem adnotacji (badanie E1), $n = 92$ pary. Źródło: opracowanie własne

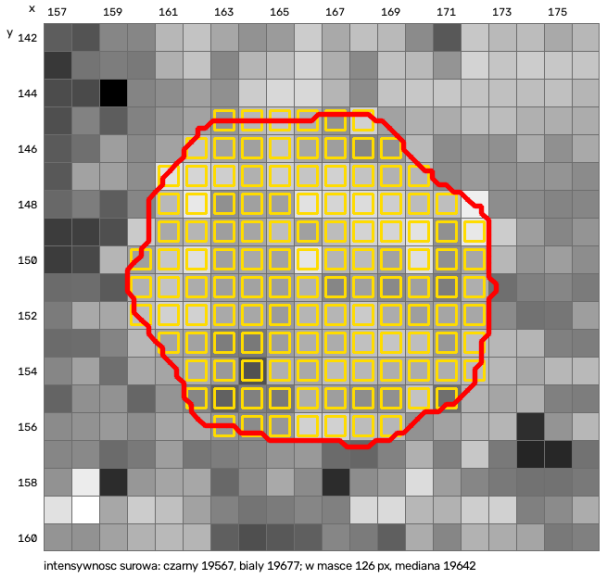
przeniesionego na obraz termowizyjny do pola zmierzonego na zdjęciu wyniósł 1,015 ± 0,034. Oba pola obliczono niezależnymi homografiami, więc wynik bliski jedności potwierdza spójność skali i rejestracji.

Tablica 6.3: Parametry znamion i piksele znamion na obrazie termowizyjnym ($n = 92$)

Wielkość	Mediana	Min.–maks.
pole znamienia, model M1 [mm^2]	3,42	1,16–28,58
pole znamienia, adnotacja CVAT [mm^2]	3,24	0,97–28,09
średnica równoważna [mm]	2,09	1,22–6,03
maksymalna średnica Fereta [mm]	2,65	1,40–8,48
kolistość	0,819	0,237–0,867
pole na obrazie termowizyjnym / pole na zdjęciu	1,020	0,767–1,069
piksele w masce znamienia	44	10–290
piksele pokryte częściowo (ułamek $< 0{,}5$)	12	3–38
odchylenie standardowe intensywności w znamieniu [j.s.]	14,1	6,0–68,4
rozstęp intensywności w znamieniu [j.s.]	65	27–333

j.s. – jednostki surowe detektora (wartości z nagrania .SEQ)

Dla 92 znamion zapisano łącznie 7337 pikseli należących do masek oraz piksele pokryte częściowo, wraz ze współrzędnymi i surową intensywnością (WF15). Przykład przedstawiono na rysunku 6.5. Zmienność intensywności w obrębie znamienia była niewielka: mediana odchylenia standardowego wyniosła 14,1 jednostek surowych. Na podstawie map temperatur wyznaczonych z parametrów kamery jednej jednostce stopnia Celsjusza odpowiada w zakresie temperatur skóry (30–37 °C) około 213 jednostek surowych, więc odchylenie to odpowiada około 0,07 °C. Wynik ten jest zgodny z obserwacją, że bez schłodzenia skóry znamię nie wyróżnia się na obrazie termowizyjnym [8]. Należy też pamiętać, że przy medianie błędu rejestracji około dwóch pikseli kamery piksele brzegowe mogą obejmować skórę wokół znamienia; dlatego dla każdego piksela zapisywany jest ułamek pokrycia.



Rysunek 6.5: Piksele obrazu termowizyjnego objęte znamieniem w parze 14: surowa intensywność z nagrania (skala szarości rozciągnięta w kadrze), znamię przeniesione ze zdjęcia (czerwona linia) i piksele w masce (żółte ramki); na brzegach współrzędne x i y pikseli. Źródło: opracowanie własne

6.6 Testy funkcjonalne

Spełnienie wymagań funkcjonalnych i części wymagań pozafunkcjonalnych sprawdzono 18 testami automatycznymi napisanymi z użyciem modułu `unittest` (tab. 6.4). Testy wykonują etapy systemu bez interfejsu graficznego na danych ze zbioru (para 14 z adnotacjami i para 75 z niewykrywalnym znacznikiem) oraz na danych przygotowanych w teście, a wyniki zapisują w folderach tymczasowych i osobnej bazie danych. Zaliczono 17 testów; test T09 pominięto, ponieważ w środowisku testowym nie było wag modelu M3. Czas wykonania całego zestawu wyniósł około 20 s.

Działanie interfejsu graficznego sprawdzono ręcznie według scenariuszy: wczytanie pary ze zbioru i własnych plików (TG1), wykonanie wszystkich etapów jednym poleceniem (TG2), praca krok po kroku z kontrolą aktywności przycisków (TG3), regulacja przezroczystości i zapis nałożenia (TG4), wyświetlanie objaśnień wielkości (TG5) oraz zapis i otwarcie raportu wraz z podglądem obrazów (TG6).

6.7 Dyskusja i ograniczenia

Zastosowanie znacznika widocznego w obu modalnościach i maksymalizacja kryterium ECC na maskach zamiast na intensywnościach zmniejszyły medianę błędu rejestracji około pięciokrotnie względem informacji wzajemnej. Bezpośrednie porównanie z wynikami innych prac jest ograniczone, ponieważ stosowano w nich inne dane i miary: błąd w pikselach przy rejestracji z szablonem kalibracyjnym [12], zgodność masek dużych obiektów (stóp) [6] albo miary podobieństwa obrazów bez błędu położenia punktów w milimetrach [14]. W niniejszej pracy błąd rejestracji wyrażono w milimetrach na płaszczyźnie znacznika, a dodatkowo zastosowano niezależną kontrolę bez adnotacji (E2), która pozwala wskazać pary wymagające sprawdzenia.

Ograniczenia przeprowadzonych badań są następujące:

Tablica 6.4: Testy funkcjonalne systemu

ID	Wymaganie	Sprawdzane zachowanie	Wynik
T01	WF1	wczytanie pary ze zbioru: obrazy, numer znamienia, adnotacje	zaliczony
T02	WF1, WN6	nieistniejący plik – komunikat zamiast awarii	zaliczony
T03	WN6	etap wywołany przed poprzednim – komunikat	zaliczony
T04	WF2, WN1, WN4	pełna rejestracja pary 14: czas 6,4 s, TRE 0,69 mm	zaliczony
T05	WN6	obraz termowizyjny bez znacznika – ostrzeżenie (zgodność z Π 0,54)	zaliczony
T06	WN6	para 75 – znacznik niezgodny z wzorcem odrzucony z komunikatem	zaliczony
T07	WF4	8 narożników w obu modalnościach, IoU wzorca $\geq 0{,}8$	zaliczony
T08	WF7, WF8	pole znamienia na obu obrazach zgodne ($\pm 15\%$), komplet parametrów	zaliczony
T09	WF6, WF9	maska M3 i miary E2 (Dice folii $\geq 0{,}9$)	pominięty*
T10	WF15	współrzędne i surowa intensywność pikseli zgodne z nagraniem	zaliczony
T11	WF15	zapis pikseli do CSV i odczyt bez utraty danych	zaliczony
T12	WF15, WN6	brak nagrania .SEQ – analiza bez pikseli, uwaga w raporcie	zaliczony
T13	WF15	własne pliki z nagraniem .SEQ – odczyt intensywności	zaliczony
T14	WF11	raport HTML, `metryki.json`, obrazy PNG i CSV pikseli	zaliczony
T15	WF12, WN9	zapis analizy, miar i pikseli w bazie	zaliczony
T16	WF12	migracja bazy ze starszej wersji schematu	zaliczony
T17	WF9	miary zgodności na maskach o znanym wyniku	zaliczony
T18	WF7	przeniesienie punktów i ułamek pokrycia pikseli	zaliczony

* wymaga wag modelu M3, niedostępnych w środowisku testowym;

- dane pochodzą z jednej serii pomiarowej, jednego zestawu urządzeń i jednej osoby wykonującej zdjęcia, a adnotacje wykonał jeden oznaczający – zgodność ekspertów przy oznaczaniu znamion jest ograniczona [3];
- model przekształcenia zakłada, że skóra w obrębie znacznika jest płaska; znacznik musi w całości znajdować się w kadrze obu urządzeń;
- obraz termowizyjny bez znacznika powoduje ostrzeżenie, ale nie przerywa rejestracji (test T05) – decyzję podejmuje użytkownik na podstawie uwag w raporcie;
- model M1 zawyża pole znamienia (mediana stosunku pól 1,10), a jego jakość na zdjęciach z telefonu oceniono tylko na 92 parach;
- intensywność pikseli jest surową wartością detektora, bez kalibracji temperatury i bez schłodzenia skóry, więc nie pozwala ocenić termicznych właściwości znamienia.

Rozdział 7

Podsumowanie

7.1 Realizacja celu pracy

Celem pracy było opracowanie, implementacja oraz ocena systemu umożliwiającego rejestrację i wspólną analizę zdjęcia RGB wykonanego telefonem i obrazu termowizyjnego zmiany skórnej. Cel ten został osiągnięty, a zadania wymienione w podrozdziale 1.2 zrealizowano w następujący sposób:

- na podstawie przeglądu literatury przyjęto rejestrację opartą na znaczniku widocznym w obu modalnościach i ocenę błędem TRE oraz miarami zgodności masek;
- zaprojektowano system w architekturze potokowej (przypadki użycia, architektura, diagram klas, interfejs) oraz bazę danych SQLite z sześcioma tabelami, przechowującą zbiór, adnotacje, wyniki analiz i piksele znamion;
- zaprojektowano znacznik Π, zebrano zbiór 94 par obrazów 34 znamion i wykonano ich adnotacje;
- zaimplementowano moduł rejestracji, modele segmentacji dla obu modalności (M1 – znamię na zdjęciu, M3 – znacznik na obrazie termowizyjnym), przeniesienie obszarów z pomiarami w milimetrach, miary zgodności oraz zapis współrzędnych i surowej intensywności pikseli znamienia;
- przygotowano aplikację z interfejsem graficznym, przetwarzanie wsadowe i raporty;
- przeprowadzono weryfikację systemu (badania E1, E2, E4, ocena segmentacji, testy funkcjonalne) oraz przygotowano instrukcję użytkownika i dokumentację techniczną (Dodatki A i B).

Wszystkie wymagania funkcjonalne o priorytecie *wymagane* zostały zrealizowane, a kryteria akceptacji wymagań pozafunkcjonalnych WN1, WN4 i WN5 – spełnione.

7.2 Wnioski

Najważniejsze wnioski z pracy są następujące:

1. Znacznik referencyjny widoczny w obu modalnościach pozwala zarejestrować zdjęcie z telefonu i obraz termowizyjny z niezależnych urządzeń z medianą błędu 0,61 mm, czyli około dwóch pikseli kamery termowizyjnej; w 85% par błąd nie przekroczył 1 mm.

2. Maksymalizacja kryterium ECC na maskach znacznika jest wyraźnie dokładniejsza od rejestracji na intensywnościach z użyciem informacji wzajemnej (mediana TRE 0,61 mm wobec 3,36 mm), ponieważ nie zależy od związku między intensywnościami obu modalności.

3. Niewielka sieć U-Net uczona na 94 obrazach wystarcza do segmentacji znacznika na obrazie termowizyjnym (współczynnik Dice'a 0,969), a porównanie jej maski z maską przeniesioną ze zdjęcia (badanie E2) pozwala bez adnotacji wskazać pary z nieudaną rejestracją.

4. Model bazowy douczony na obrazach dermatoskopowych może segmentować znamiona na zdjęciach z telefonu (współczynnik Dice'a 0,870) pod warunkiem ograniczenia obszaru do wnętrza znacznika i doboru kadru zgodnego z danymi uczącymi; model zawyża jednak pole znamienia.

5. System dostarcza dla każdego znamienia listę pikseli obrazu termowizyjnego z ich współrzędnymi i surową intensywnością. W obrazach statycznych, wykonanych bez schłodzenia skóry, zmienność intensywności w obrębie znamienia jest niewielka (około 0,07 °C), co uzasadnia rozszerzenie badań o termografię dynamiczną.

7.3 Kierunki dalszych prac

Ograniczenia opisane w podrozdziale 6.7 wyznaczają kierunki dalszych prac:

- rozszerzenie systemu o termografię dynamiczną – rejestrację sekwencji obrazów po schłodzeniu skóry i analizę zmian intensywności pikseli znamienia w czasie;
- douczenie modelu M1 na zdjęciach z telefonu z walidacją krzyżową według znamion, aby ograniczyć zawyżanie pola znamienia;
- przerywanie analizy, gdy znacznik na obrazie termowizyjnym jest wykryty niepewnie, oraz automatyczne oznaczanie par z niską zgodnością w badaniu E2;
- zebranie kolejnych serii pomiarowych z udziałem większej liczby osób, urządzeń i oznaczających, co pozwoli ocenić zmienność adnotacji i uogólnienie modeli;
- przeliczanie intensywności na temperaturę z kalibracją kamery oraz ocena użyteczności systemu z udziałem lekarzy.

Bibliografia

[1] Celebi, M. E., Codella, N., and Halpern, A. Dermoscopy image analysis: Overview and future directions. *IEEE Journal of Biomedical and Health Informatics 23*, 2 (2019), 474–478.

[2] Chen, X., Diaz-Pinto, A., Ravikumar, N., and Frangi, A. F. Deep learning in medical image registration. *Progress in Biomedical Engineering 3*, 1 (2021), 012003.

[3] Codella, N., Rotemberg, V., Tschandl, P., Celebi, M. E., Dusza, S., Gutman, D., Helba, B., Kalloo, A., Liopyris, K., Marchetti, M., Kittler, H., and Halpern, A. Skin lesion analysis toward melanoma detection 2018: A challenge hosted by the International Skin Imaging Collaboration (ISIC). arXiv:1902.03368, 2019.

[4] Evangelidis, G. D., and Psarakis, E. Z. Parametric image alignment using enhanced correlation coefficient maximization. *IEEE Transactions on Pattern Analysis and Machine Intelligence 30*, 10 (2008), 1858–1865.

[5] Fitzpatrick, J. M., West, J. B., and Maurer, C. R. Predicting error in rigid-body point-based registration. *IEEE Transactions on Medical Imaging 17*, 5 (1998), 694–702.

[6] González-Pérez, S., Perea Ström, D., Arteaga-Marrero, N., Luque, C., Sidrach-Cardona, I., Villa, E., and Ruiz-Alzola, J. Assessment of registration methods for thermal infrared and visible images for diabetic foot monitoring. *Sensors 21*, 7 (2021), 2264.

[7] Han, J., Pauwels, E. J., and de Zeeuw, P. Visible and infrared image registration in man-made environments employing hybrid visual features. *Pattern Recognition Letters 34*, 1 (2013), 42–51.

[8] Herman, C., and Pirtini Cetingul, M. Quantitative visualization and detection of skin cancer using dynamic thermal imaging. *Journal of Visualized Experiments 51* (2011), e2679.

[9] Hu, Y., Modat, M., Gibson, E., Li, W., Ghavami, N., Bonmati, E., Wang, G., Bandula, S., Moore, C. M., Emberton, M., Ourselin, S., Noble, J. A., Barratt, D. C., and Vercauteren, T. Weakly-supervised convolutional neural networks for multimodal image registration. *Medical Image Analysis 49* (2018), 1–13.

[10] Magalhaes, C., Vardasca, R., Rebelo, M., Valença-Filipe, R., Ribeiro, M., and Mendes, J. Distinguishing melanocytic nevi from melanomas using static and dynamic infrared thermal imaging. *Journal of the European Academy of Dermatology and Venereology 33*, 9 (2019), 1700–1705.

[11] Maier-Hein, L., et al. Metrics reloaded: recommendations for image analysis validation. *Nature Methods 21*, 2 (2024), 195–212.

[12] Maurya, L., Mahapatra, P., and Chawla, D. Non-contact breathing monitoring by integrating RGB and thermal imaging via RGB-thermal image registration. *Biocybernetics and Biomedical Engineering 41* (2021), 1107–1122.

[13] Mirikharaji, Z., et al. A survey on deep learning for skin lesion segmentation. *Medical Image Analysis 88* (2023), 102863.

[14] Oniga, M., Rus, P. F., et al. A heatmap-based deep learning framework for multi-modal registration of VIS, NIR, and thermal images in dermatological imaging. *Frontiers in Artificial Intelligence 9* (2026), 1807482.

[15] Ring, E. F. J., and Ammer, K. Infrared thermal imaging in medicine. *Physiological Measurement 33*, 3 (2012), R33–R46.

[16] Roche, A., Malandain, G., Pennec, X., and Ayache, N. The correlation ratio as a new similarity measure for multimodal image registration. In *Medical Image Computing and Computer-Assisted Intervention – MICCAI'98* (1998), vol. 1496 of *Lecture Notes in Computer Science*, Springer, pp. 1115–1124.

[17] Ronneberger, O., Fischer, P., and Brox, T. U-Net: Convolutional networks for biomedical image segmentation. In *Medical Image Computing and Computer-Assisted Intervention – MICCAI 2015* (2015), vol. 9351 of *Lecture Notes in Computer Science*, Springer, pp. 234–241.

[18] Taha, A. A., and Hanbury, A. Metrics for evaluating 3D medical image segmentation: analysis, selection, and tool. *BMC Medical Imaging 15* (2015), 29.

[19] Tschandl, P., Rosendahl, C., and Kittler, H. The HAM10000 dataset, a large collection of multi-source dermatoscopic images of common pigmented skin lesions. *Scientific Data 5* (2018), 180161.

[20] Xiao, T., Liu, Y., Zhou, B., Jiang, Y., and Sun, J. Unified perceptual parsing for scene understanding. In *Computer Vision – ECCV 2018* (2018), vol. 11209 of *Lecture Notes in Computer Science*, Springer, pp. 432–448.

[21] Yan, S., Yu, Z., Primiero, C., Vico-Alonso, C., Wang, Z., et al. A multimodal vision foundation model for clinical dermatology. *Nature Medicine 31*, 8 (2025), 2691–2702.

[22] Zhang, X., and Demiris, Y. Visible and infrared image fusion using deep learning. *IEEE Transactions on Pattern Analysis and Machine Intelligence 45*, 8 (2023), 10535–10554.

[23] Zitová, B., and Flusser, J. Image registration methods: a survey. *Image and Vision Computing 21*, 11 (2003), 977–1000.

Dodatek A

Instrukcja użytkownika

Instrukcja opisuje analizę pary obrazów zmiany skórnej w aplikacji okienkowej systemu. Instalację środowisk opisano w dokumentacji technicznej (Dodatek B).

A.1 Uruchomienie

Aplikację uruchamia się w systemie Windows poleceniem:

```
inzynierka\Scripts\python.exe projekt\aplikacja.py
```

wydanym w folderze głównym projektu. Segmentacja znamienia wymaga zainstalowanego środowiska modeli; pozostałe etapy działają bez niego.

A.2 Przygotowanie obrazów

Przed wykonaniem zdjęć należy nakleić znacznik Π tak, aby znamię znajdowało się między jego ramionami, w otworze znacznika. Znacznik musi w całości mieścić się w kadrze zarówno telefonu, jak i kamery termowizyjnej. Zdjęcie należy wykonać możliwie prostopadle do skóry, bez lampy błyskowej i bez silnych odblasków na folii. Z kamery termowizyjnej zapisuje się nagranie .SEQ; aby system zapisał intensywność pikseli znamienia, obraz termowizyjny (JPG) i nagranie muszą mieć tę samą nazwę i leżeć w tym samym folderze. Dla par ze zbioru nagrania są przypisane automatycznie.

A.3 Analiza pary krok po kroku

Okno aplikacji (rys. 4.4) składa się z paska sześciu etapów, panelu sterowania po lewej stronie, podglądów obrazów po prawej oraz paska stanu z dziennikiem zdarzeń. Kółko myszy powiększa podgląd, przeciąganie przesuwa obraz, a dwukrotne kliknięcie przywraca widok początkowy. Przyciski etapów, których nie można jeszcze wykonać, są nieaktywne. Kolejne kroki analizy przedstawiono w tabeli A.1. Wszystkie etapy można też wykonać jednym poleceniem *Wykonaj wszystkie etapy* w zakładce *1. Dane*; po jego zakończeniu aplikacja przechodzi do zakładki raportu.

Tablica A.1: Analiza pary obrazów w aplikacji

Zakładka	Czynność użytkownika	Wynik
1. Dane	wybrać *Para z bazy*, numer pary (przyciski ze strzałkami zmieniają parę) i kliknąć *Wczytaj parę*; albo wybrać *Własne pliki*, wskazać zdjęcie i obraz termowizyjny i kliknąć *Wczytaj pliki*	podgląd obu obrazów; informacje o parze, adnotacjach i nagraniu .SEQ
2. Rejestracja	kliknąć *Uruchom rejestrację* (lub *Wczytaj zapisaną rejestrację*); suwakiem ustawić przezroczystość; opcjonalnie *Zapisz nałożenie...*	nałożenie obrazów, model przekształcenia, kontury znacznika z obu modalności
3. Segmentacja	kliknąć *Wyznacz narożniki, znamię i znacznik na termowizji*	narożniki 0–7, maska znamienia na zdjęciu, maska znacznika na obrazie termowizyjnym
4. Przeniesienie ROI	kliknąć *Przenieś na termowizję*; przełączyć widok zdjęcia (*Zdjęcie* / *Nałożenie*)	znamię i znacznik na obrazie termowizyjnym
5. Pomiary	kliknąć *Oblicz pomiary i zgodność*; kliknąć nazwę wielkości w tabeli, aby wyświetlić jej objaśnienie	tabela wyników (badanie E2, kontrola skali, parametry znamienia, piksele znamienia) oraz uwagi
6. Raport	kliknąć *Zapisz raport*, następnie *Otwórz raport* lub *Otwórz folder wyników*; przełączać podgląd obrazów raportu	pliki raportu (tab. A.2)

A.4 Wyniki

Wyniki zapisywane są w folderze `wyniki\wyniki_obu\para_N` (dla własnych plików – w folderze nazwanym od nazw plików), który można zmienić w zakładce raportu. Zawartość folderu opisano w tabeli A.2. Raport otwiera się w dowolnej przeglądarce; na jego początku znajdują się uwagi wymagające sprawdzenia, a na końcu objaśnienia wszystkich wielkości.

Tablica A.2: Pliki wynikowe analizy pary

Plik	Zawartość
`raport.html`	raport z obrazami, tabelami wyników, uwagami i objaśnieniami
`metryki.json`	wszystkie wyniki liczbowe (do dalszej analizy)
`rgb.png`, `termal.png`, `nakladka.png`, `nakladka_zblizenie.png`, `znacznik_modalnosci.png`, `piksele_termal.png`	obrazy raportu: zdjęcie i obraz termowizyjny z obrysami, nałożenie, powiększenie wokół znamienia, maski badania E2, piksele znamienia
`piksele_znamienia_termal.csv`	piksele znamienia na obrazie termowizyjnym: `x`, `y` (kolumna i wiersz), `ulamek` (pokrycie piksela przez znamię), `w_masce` (1 – pokrycie co najmniej 50%), `intensywnosc` (surowa wartość z nagrania .SEQ); separator średnik

A.5 Komunikaty i rozwiązywanie problemów

Najczęstsze komunikaty i sposób postępowania przedstawiono w tabeli A.3. Komunikaty błędów wyświetlane są w oknie dialogowym, a ich szczegóły – w dzienniku zdarzeń.

Tablica A.3: Komunikaty systemu i sposób postępowania

Komunikat lub uwaga	Przyczyna	Postępowanie
Nie można otworzyć zdjęcia / obrazu termowizyjnego	plik nie istnieje lub ma nieobsługiwany format	wskazać plik JPG lub PNG
Nie znaleziono znacznika, znacznik wykryty niepewnie	znacznik ucięty przez kadr, zasłonięty lub z silnym odblaskiem	sprawdzić nałożenie; w razie błędu powtórzyć zdjęcie
Najpierw wykonaj ...	pominięto wcześniejszy etap	wykonać etapy w kolejności zakładek
Nie ma środowiska modeli z PyTorch	brak środowiska modelu M1	zainstalować środowisko modeli (Dodatek B)
Brak surowej intensywności termowizji	brak nagrania .SEQ o tej samej nazwie co obraz	umieścić nagranie obok obrazu i powtórzyć pomiary
niska zgodność masek między modalnościami (E2) lub błąd narożników powyżej 1 mm	możliwy błąd rejestracji lub segmentacji	ocenić nałożenie; wyników pary nie używać bez sprawdzenia

Dodatek B

Dokumentacja techniczna

Dokumentacja jest przeznaczona dla osoby instalującej, utrzymującej lub rozwijającej system. Kod źródłowy znajduje się w folderze `projekt`, a szczegółowe opisy – w plikach `README.md` folderów `projekt` i `projekt/modele_segmentacja`.

B.1 Środowiska i instalacja

System korzysta z dwóch środowisk języka Python (tab. B.1). Środowisko aplikacji jest lekkie i nie zawiera biblioteki PyTorch; środowisko modeli służy do segmentacji znamienia modelem M1, uczenia modeli oraz przetwarzania wsadowego. Ścieżki środowiska modeli, wag i zbiorów danych zdefiniowano w module `modele_segmentacja/konfiguracja.py`; katalog bazowy można zmienić zmienną środowiskową `MODELE_DANE`.

Tablica B.1: Środowiska uruchomieniowe systemu

	Środowisko aplikacji	Środowisko modeli
położenie	`inzynierka\` (folder główny projektu)	`%USERPROFILE%\modele_dane\srodowisko\`
Python	3.14	3.12
biblioteki	customtkinter, OpenCV, NumPy, Pillow, flirpy, matplotlib; SimpleITK (tylko badanie E4)	PyTorch 2.11 z CUDA 12.8, torchvision, OpenCV, NumPy, bitsandbytes, SimpleITK, onnx (lista: `modele_segmentacja/wymagania_srodowiska.txt`)
zastosowanie	aplikacja, model M3 (ONNX), testy	model M1, uczenie modeli, potok wsadowy, raport zbiorczy

Instalacja środowiska aplikacji (w folderze głównym projektu):

```
py -3.14 -m venv inzynierka
inzynierka\Scripts\pip install customtkinter opencv-python numpy pillow ^
    flirpy matplotlib simpleitk
```

Środowisko modeli tworzy się analogicznie z pliku `wymagania_srodowiska.txt` (`pip install -r`). Wagi modeli umieszcza się w katalogu `modele_dane\wagi`: koder PanDerm i wytrenowany model M1 w podkatalogu modelu, a model M3 jako pliki `unet_termal\fold1.onnx`–`fold5.onnx` i `wszystkie.onnx`.

B.2 Struktura kodu

Etapy systemu zrealizowano w pakiecie `analiza`, wspólnym dla aplikacji i przetwarzania wsadowego (tab. B.2). Modele segmentacji znajdują się w pakiecie `modele_segmentacja`, a metoda rejestracji – w module `dopasowanie3.py`.

Tablica B.2: Moduły pakietu `analiza` i główne moduły projektu

Moduł	Odpowiedzialność
`analiza/system.py`	klasa `Analiza` (etapy potoku), wyjątek `BladEtapu`, funkcje `analizuj`, `analizuj_z_zapisanych`
`analiza/dane.py`	dane par ze zbioru, adnotacje z CVAT, surowa intensywność z nagrań .SEQ
`analiza/geometria.py`	przenoszenie punktów i masek macierzą T, ułamek pokrycia, skala mm/piksel
`analiza/miary.py`	Dice, IoU, HD95, ASSD, przesunięcie środków, stosunek pól, TRE
`analiza/pomiary.py`	parametry znamienia, piksele znamienia na obrazie termowizyjnym i ich zapis do CSV
`analiza/obrazy.py`, `raport.py`	obrazy raportu i raport HTML z objaśnieniami
`analiza/baza.py`	klasa `Baza` (SQLite), schemat, migracja, import i eksport
`dopasowanie3.py`	detekcja znacznika, dopasowanie wstępne, ECC, wybór modelu przekształcenia
`modele_segmentacja/`	interfejs `ModelSegmentacji`, model M1, kandydaci na znamię, model M3 (`unet_termal/`)
`aplikacja.py`	interfejs graficzny (klasy `Aplikacja`, `Podglad`)

Klasa `Analiza` udostępnia metody odpowiadające etapom potoku, które należy wywoływać w kolejności przedstawionej na listingu B.1. Wywołanie etapu bez wyniku poprzedniego kończy się wyjątkiem `BladEtapu` z opisem brakującego kroku.

Listing B.1: Analiza pary bez interfejsu graficznego

```
from analiza.system import Analiza
a = Analiza.z_pary(14)          # albo Analiza("zdjecie.jpg", "termal.jpg")
a.rejestruj()                   # macierz T
a.ustaw_narozniki()             # narozniki i skala mm
a.segmentuj_znamie()            # model M1 (srodowisko modeli)
a.segmentuj_znacznik_termal()   # model M3 (ONNX)
a.przenies(); a.zmierz()        # przeniesienie ROI, pomiary, piksele
print(a.zapisz_raport())        # raport, metryki.json, CSV, wpis w bazie
```

B.3 Formaty danych

Dane pary przechowywane są w folderze `dane/pary/N`: zdjęcie `rgb.jpg`, obraz termowizyjny `termal.jpg`, surowe wartości detektora `termal_surowe.npy` (macierz 240×320, `uint16`), mapa temperatur `termal_C.npy`, maski z CVAT (PNG, 0/255) oraz `narozniki.json` z narożnikami i homografiami piksele–milimetry obu modalności. Wynik rejestracji zapisywany jest w folderze `wyniki/wyniki_dopasowania/para_N`, m.in. jako macierz T w pliku tekstowym `dopasowanie_macierz.txt` (3×3, piksel zdjęcia $\rightarrow$ piksel obrazu termowizyjnego). Plik `metryki.json` zawiera wyniki pogrupowane według badań (`rejestracja`, `zgodnosc`, `zgodnosc_modalnosci`, `pomiary_rgb`, `kontrola_skali`, `piksele_termal` i in.), a format pliku pikseli opisano w tabeli A.2.

B.4 Baza danych

Schemat bazy (rys. 4.2) zdefiniowano w module `analiza/baza.py`. Numer wersji schematu jest zapisywany w polu `user_version` pliku bazy (obecnie 2); przy otwarciu starszej bazy tworzone są brakujące tabele. Obsługę bazy z wiersza poleceń zapewnia skrypt `baza_danych.bat` z poleceniami `utworz`, `importuj_wyniki`, `pokaz`, `eksport`, `eksport_piksele` i `sql`. Przykładowe zapytania przedstawiono na listingu B.2.

Listing B.2: Przykładowe zapytania do bazy danych

```
-- wspolczynnik Dice'a otworu (badanie E2) dla wszystkich par
SELECT para, wartosc FROM wyniki_par
 WHERE grupa = 'zgodnosc_modalnosci.otwor' AND nazwa = 'dice';
-- piksele znamienia pary 14 z ostatniej analizy
SELECT x, y, intensywnosc FROM piksel
 WHERE w_masce = 1 AND analiza_id =
   (SELECT id FROM ostatnia_analiza WHERE para_id = 14);
```

B.5 Skrypty pomocnicze, uczenie i testy

Skrypty wsadowe uruchamia się z folderu `projekt` (tab. B.3). Testy funkcjonalne (podrozdział 6.6) uruchamia skrypt `testy/uruchom_testy.bat`, który zapisuje wynik w pliku `testy/wynik_testow.txt`.

Tablica B.3: Skrypty pomocnicze systemu

Skrypt	Zadanie
`potok_pary.bat 1-94 [-z_zapisanych]`	analiza wskazanych par (z zapisaną rejestracją i maskami M1 – bez GPU)
`raport_zbiorczy.bat`	raport zbiorczy wszystkich par i tabele LaTeX
`porownaj_rejestracje.py`	badanie E4: porównanie metod rejestracji
`read_flirpy.py`, `heic_do_jpg.py`	konwersja nagrań .SEQ i zdjęć HEIC
`temperatury_par.py [-tylko_surowe]`	mapy temperatur i surowe wartości detektora dla par
`import_cvat.py`	import adnotacji z programu CVAT
`modele_segmentacja/trenuj_pandermon.bat`	uczenie modelu M1 na zbiorze ISIC 2018
`modele_segmentacja/trenuj_unet_termal.bat`, `ocen_unet_termal.bat`	uczenie modelu M3 (5 foldów i model końcowy) i jego ocena

B.6 Rozszerzanie systemu

Nowy model segmentacji znamienia dodaje się jako podkatalog `modele_segmentacja/modele` z klasą `Model` dziedziczącą po `ModelSegmentacji`; model jest wykrywany automatycznie. Nowa miara dopisana do słownika wyników trafia automatycznie do pliku `metryki.json` i tabeli `miara`, bez zmiany schematu bazy. Parametry metody rejestracji – model przekształcenia (`MODEL`), próg zgodności z wzorcem (`MIN_ZGODNOSC`) i rozdzielczość roboczą zdjęcia (`RGB_DET_PX`) – zdefiniowano jako stałe w module `dopasowanie3.py`.